IPADS INSTITUTE OF PARALLEL AND DISTRIBUTED SYSTEMS

上海交通大學 SHANGHAI JIAO TONG UNIVERSITY

新型文件系统

陈海波 / 夏虞斌

上海交通大学并行与分布式系统研究所

https://ipads.se.sjtu.edu.cn

版权声明

- 本内容版权归**上海交通大学并行与分布式系统研究所**所有
- 使用者可以将全部或部分本内容免费用于非商业用途
- 使用者在使用全部或部分本内容时请注明来源：
  - 内容来自：上海交通大学并行与分布式系统研究所+材料名字
- 对于不遵守此声明或者其他违法使用本内容者，将依法保留追究权
- 本内容的发布采用 Creative Commons Attribution 4.0 License
  - 完整文本：https://creativecommons.org/licenses/by/4.0/legalcode

LFS回顾：检查点（Checkpoint）

- 检查点内容
  - inode map的位置（可找到所有文件的内容）
  - 段使用表
  - 当前时间
  - 最后写入的段的指针

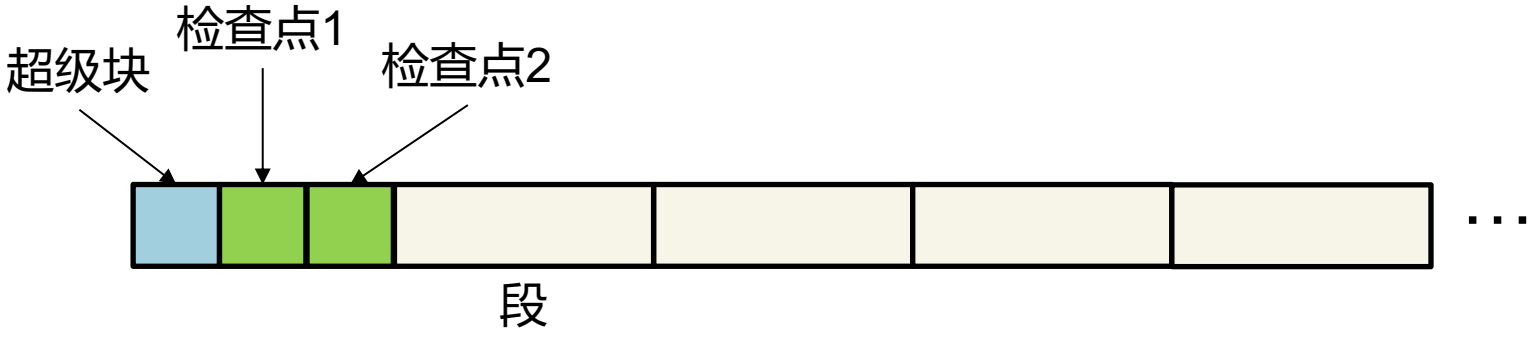

LFS回顾：前滚（roll-forward）

- 尽量恢复检查点后写入的数据
- 通过段概要里面的新inode，恢复新的inode
  - 其inode中的数据块会被恢复
- 未被inode"认领"的数据块会被删除

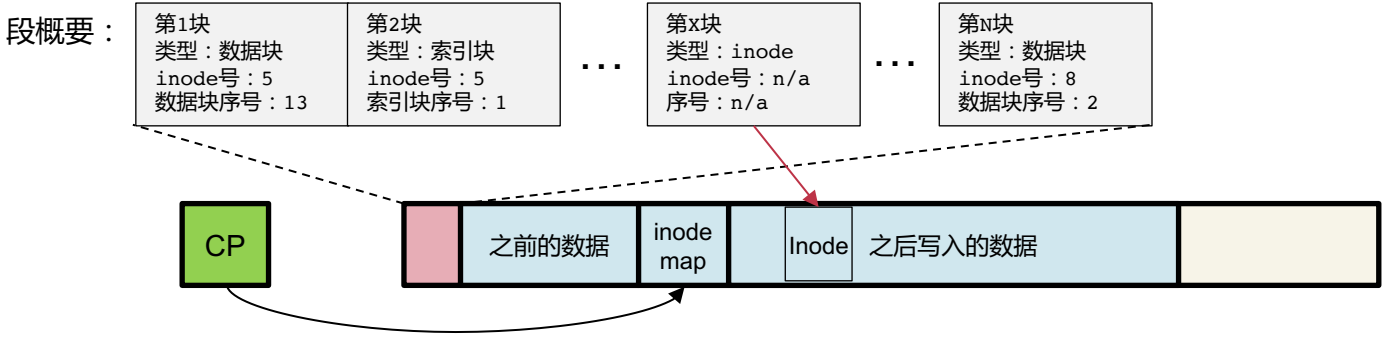

LFS回顾：前滚（roll-forward）

- 段概要无法保证inode的链接数一致性
  - 如：inode被持久化，但是指向其的目录项未被持久化

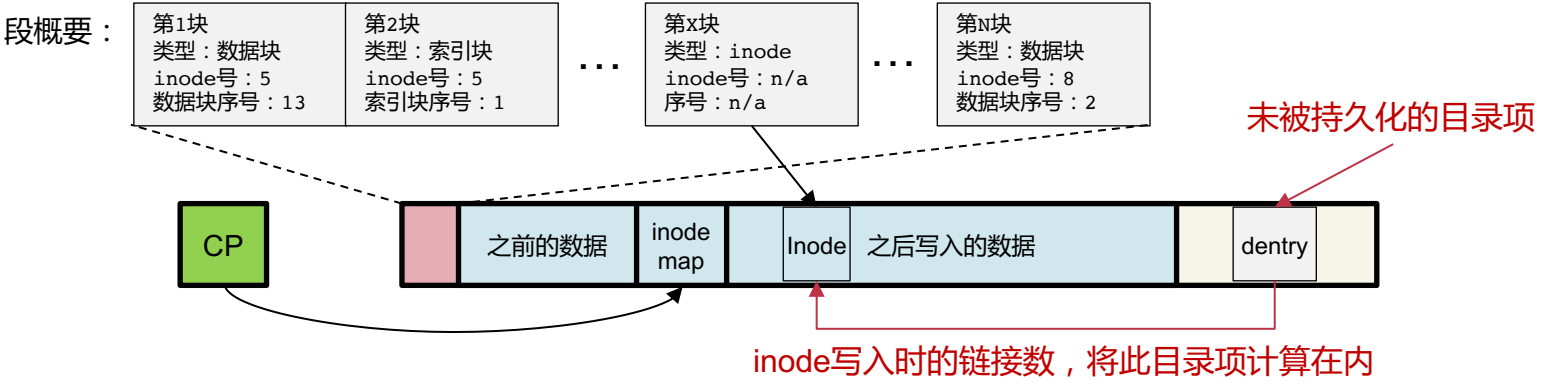

LFS回顾：前滚（roll-forward）

- 段概要无法保证inode的链接数一致性
  - 如：inode被持久化，但是指向其的目录项未被持久化
- 解决方案：目录修改日志

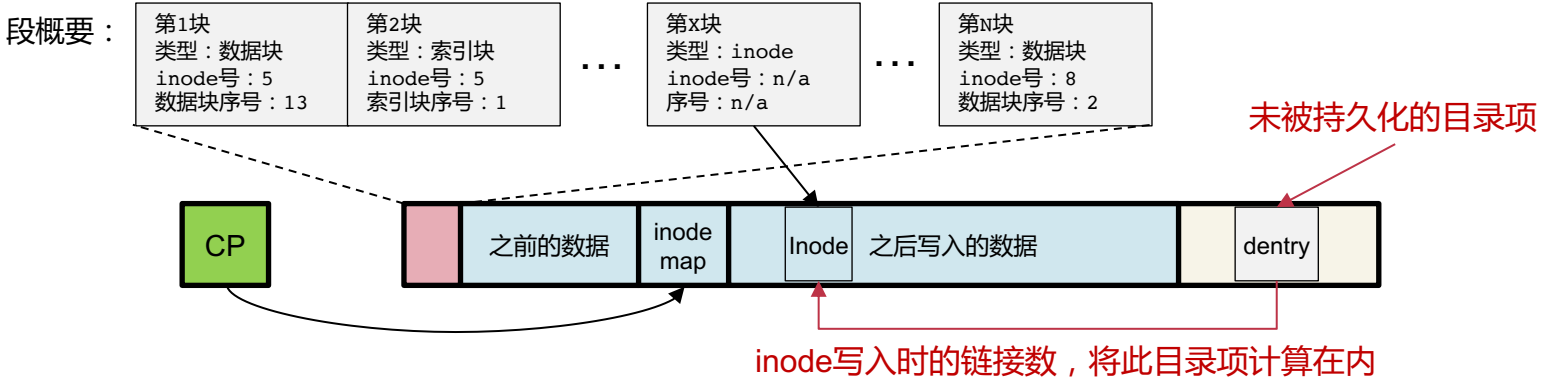

LFS回顾：目录修改的日志

- 目录修改日志
  - 记录了每个目录操作的信息
    - create、link、rename、unlink
  - 以及操作的具体信息
    - 目录项位置、内容、inode的链接数
- 目录修改日志的持久化在目录修改之前
  - 恢复时根据目录修改日志保证inode的链接数是一致的

Flash友好的文件系统

F2FS

Lee, Changman, Dongho Sim, Jooyoung Hwang, and Sangyeun Cho. *F2FS: A new file system for flash storage*. In *FAST '15*.

闪存盘的组织

- (NAND) 闪存盘组织结构
  - A chip/package
    => 1/2/4 dies
    => 1/2 planes
    => n blocks（块）
    => n pages（页）
    => n cells
    => 1/2/3/4 levels

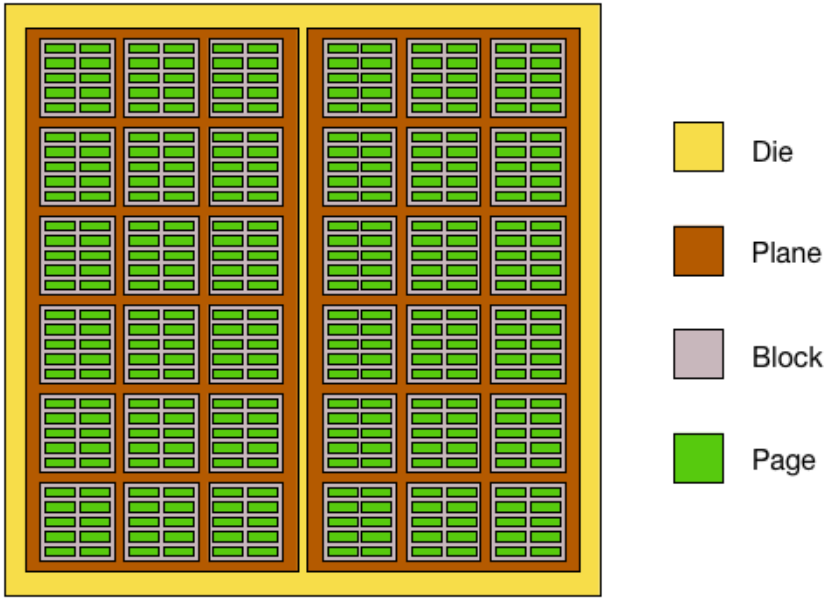

https://www.extremetech.com/electronics/274944-samsungs-new-v-nand-could-mean-cheap-plentiful-multi-terabyte-ssds

闪存盘的组织

- **通道（Channel）**
  - 控制器可以同时访问的闪存芯片数量
- **多通道（Multi-channel）**
  - 低端盘有2或4个通道
  - 高端盘有8或10个通道

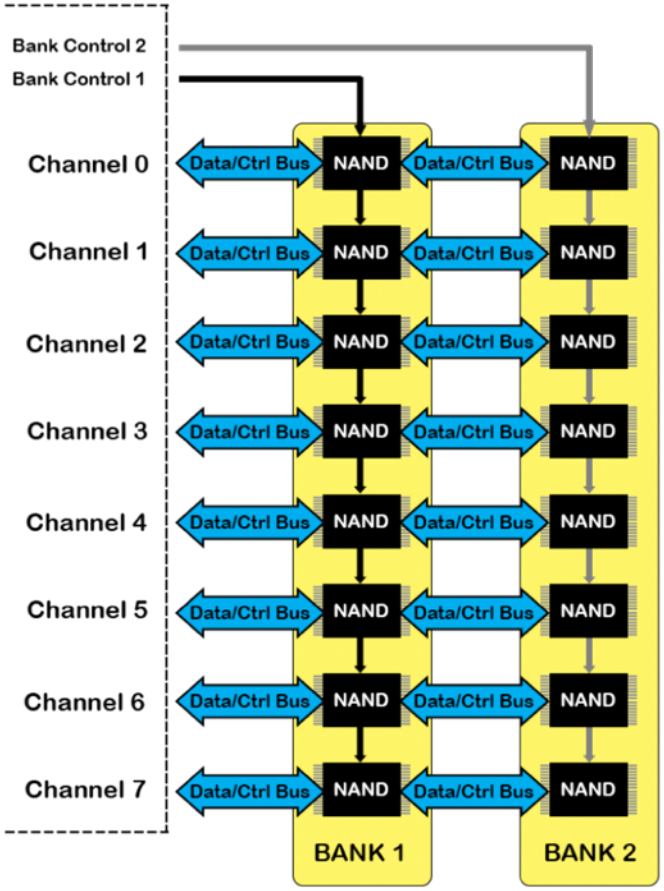

NAND Banks and Channels Illustration

https://www.cactus-tech.com/resources/blog/details/solid-state-drive-primer-8-controller-architecture-channels-and-banks/

闪存盘的性质

- **非对称的读写与擦除操作**
  - 页 (page) 是读写单元 (8-16KB)
  - 块 (block) 是擦除单元 (4-8MB)
- **Program/Erase cycles**
  - 写入前需要先擦除
  - 每个块被擦除的次数是有限的
- **随机访问性能**
  - 没有寻道时间
  - 随机访问的速度提升，但仍与顺序访问有一定差距

闪存盘的性质

- **磨损均衡**
  - 频繁写入同一个块会造成写穿问题
  - 将写入操作均匀的分摊在整个设备
- **多通道**
  - 高并行性
- **异质Cell**
  - 存储1到4个比特：SLC 、MLC、TLC、 QLC

Flash Translation Layer (FTL)

- 逻辑地址到物理地址的转换
  - 对外使用逻辑地址
  - 内部使用物理地址
  - 可软件实现，也可以固件实现
  - 用于垃圾回收、数据迁移、磨损均衡（wear-levelling）等

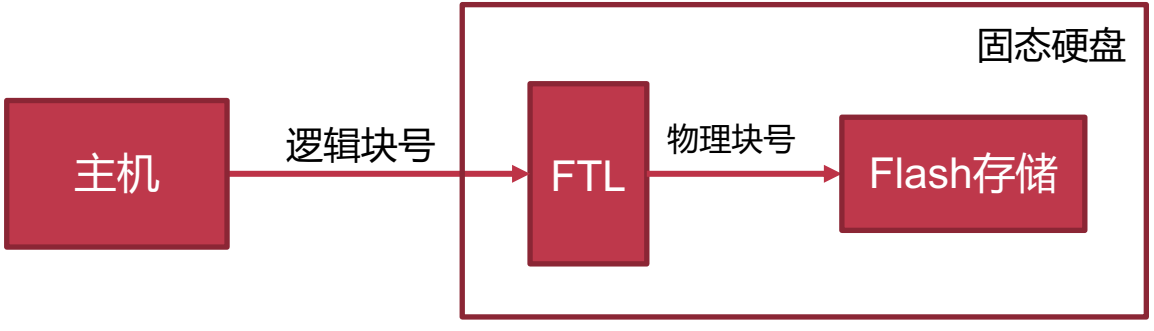

问题：如何为Flash设计文件系统 ？

LFS与Flash很相似？

- LFS
  - Segment清理后才能使用
  - 顺序写入
  - 需要清理（垃圾回收）
- Flash
  - Block擦除后才能使用
  - 需要考虑磨损均衡
  - 需要垃圾回收

LFS的结构

逻辑结构

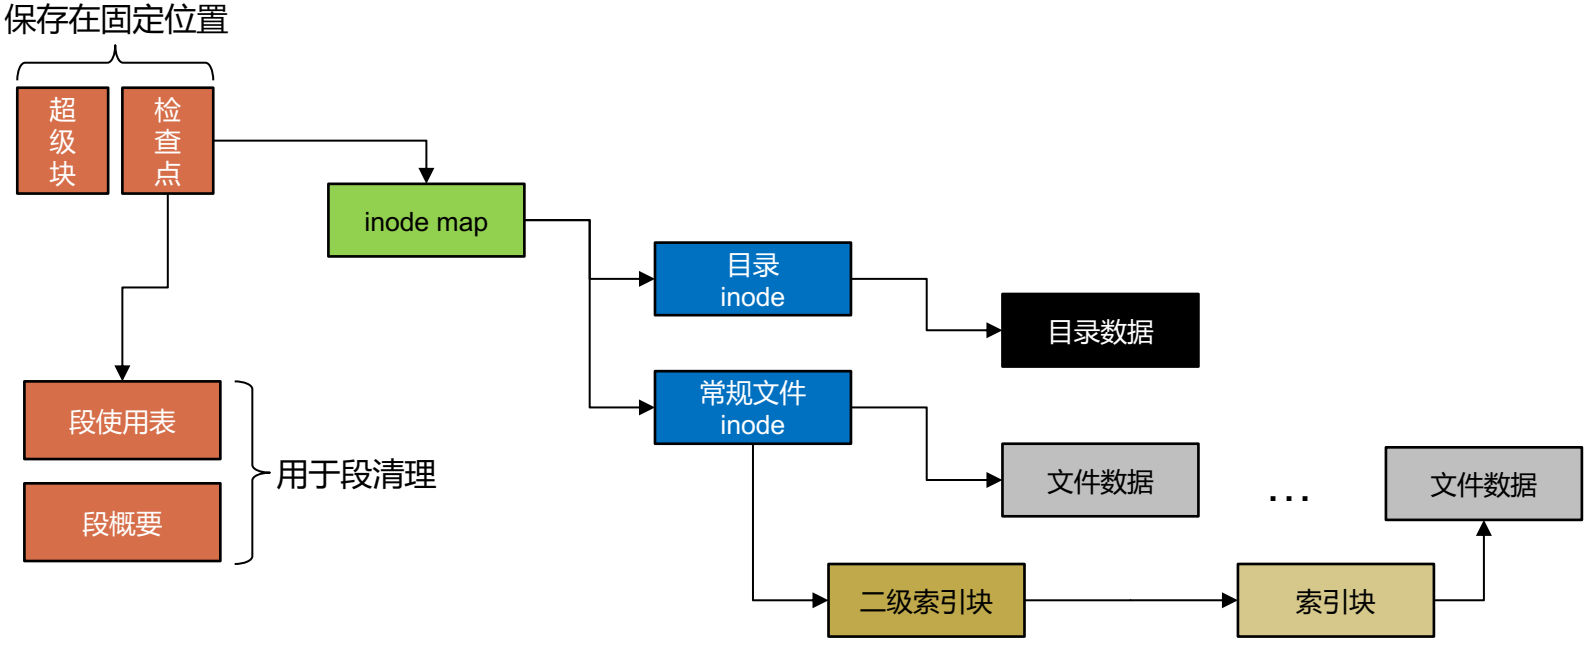

存储结构

LFS的问题1：递归更新问题

逻辑结构

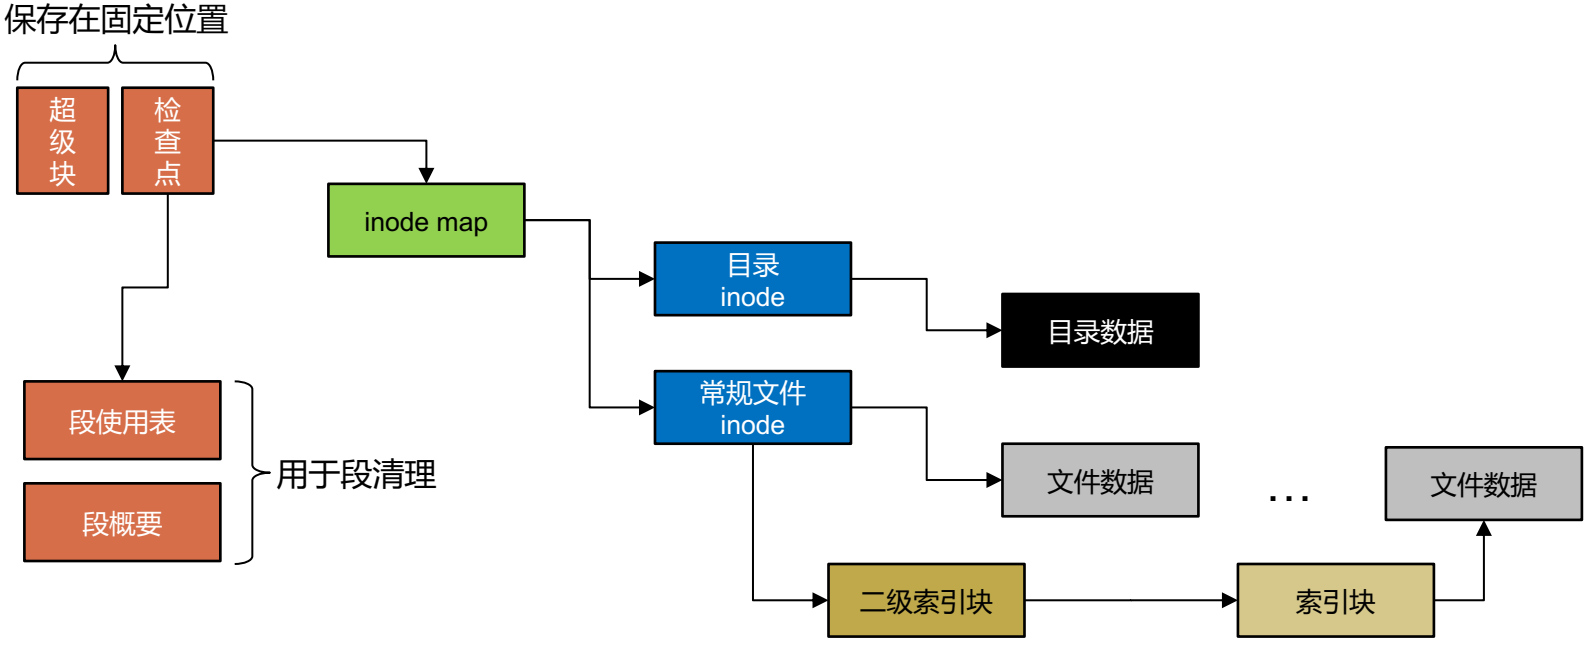

存储结构

LFS的问题1：递归更新问题

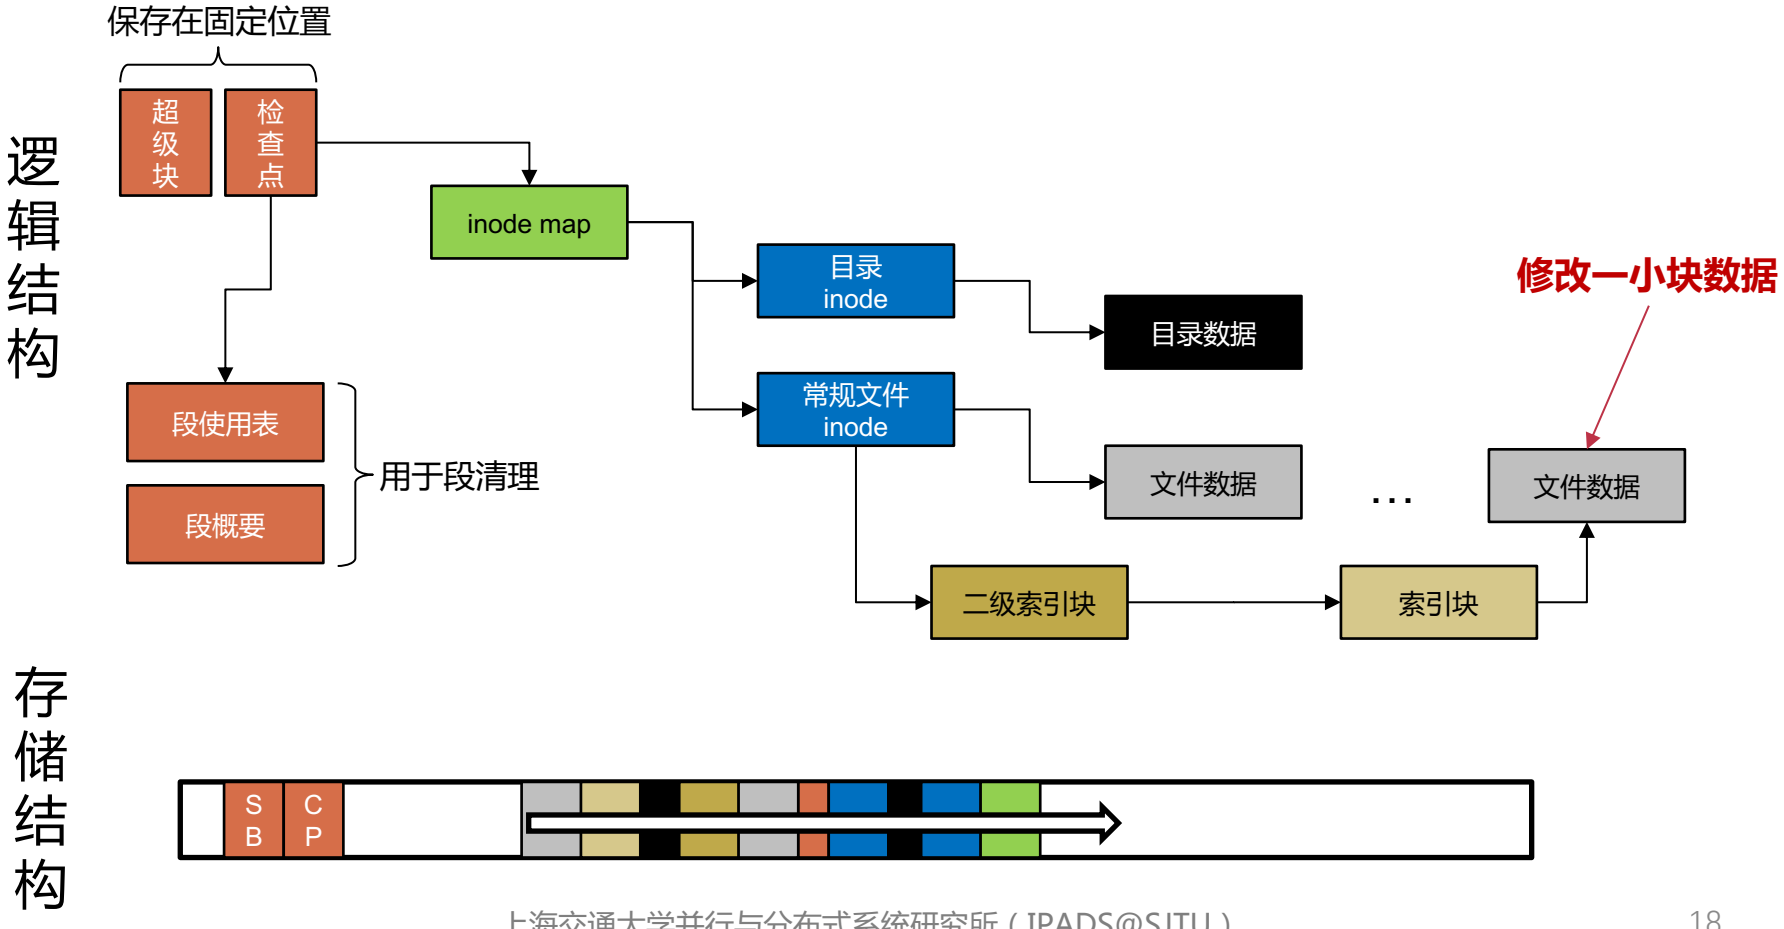

LFS的问题1：递归更新问题

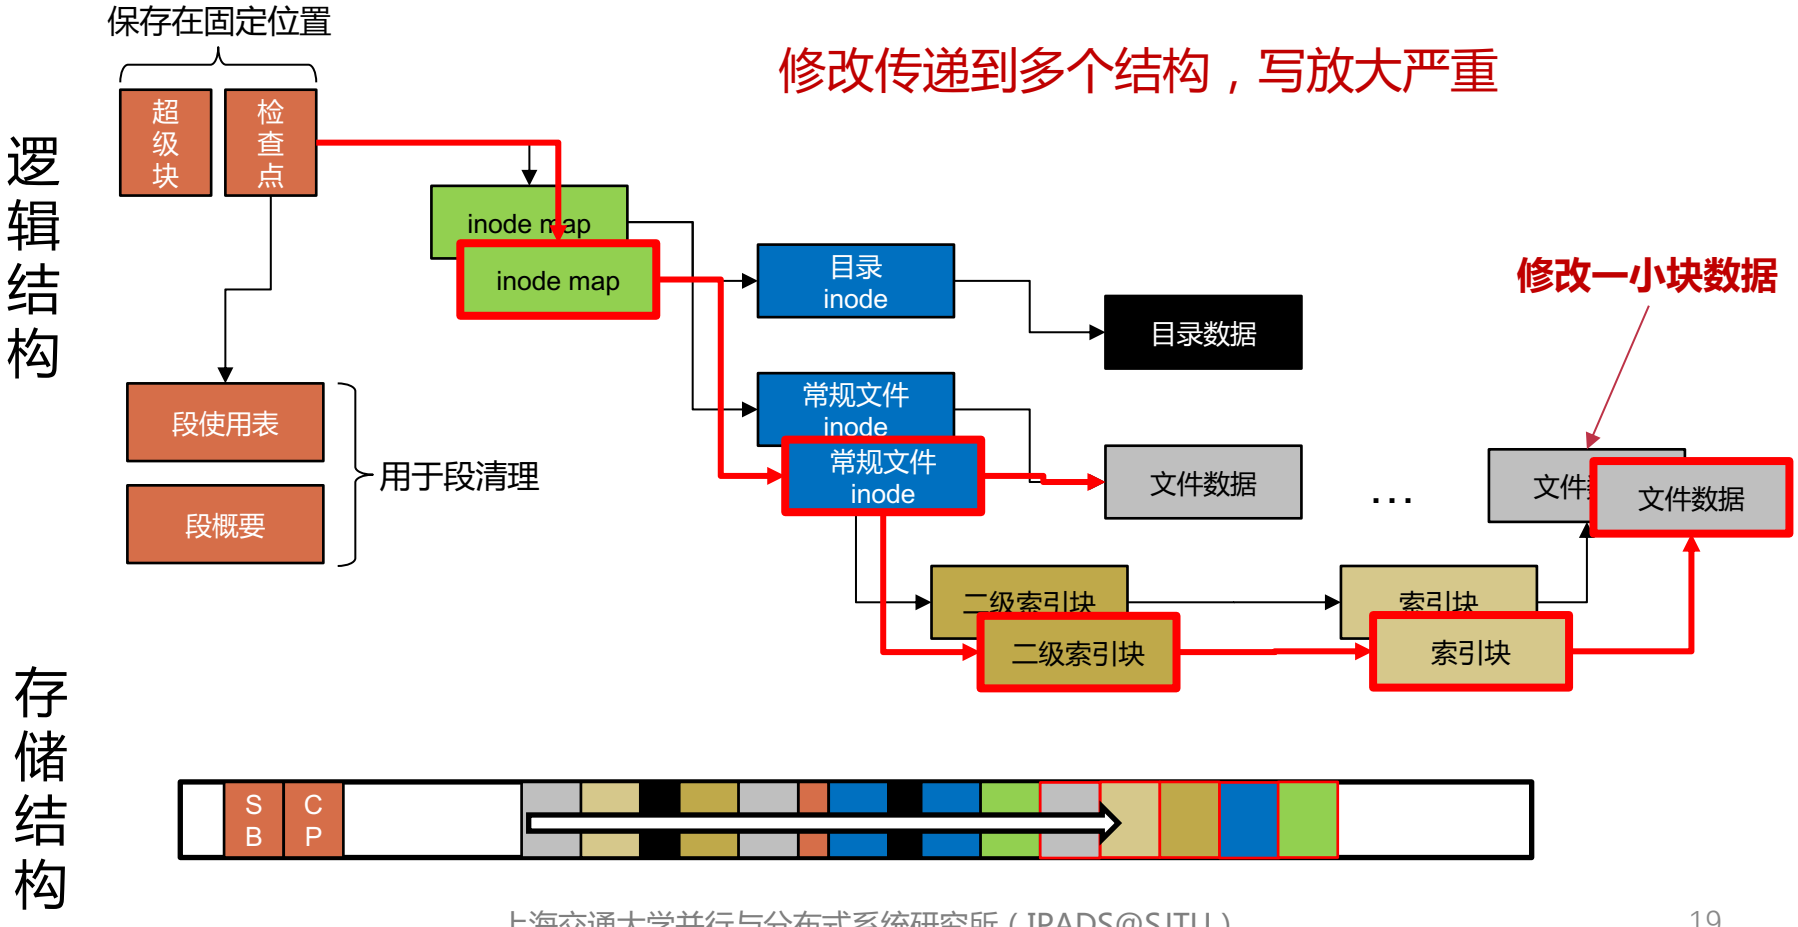

LFS的问题2：单一log顺序写入

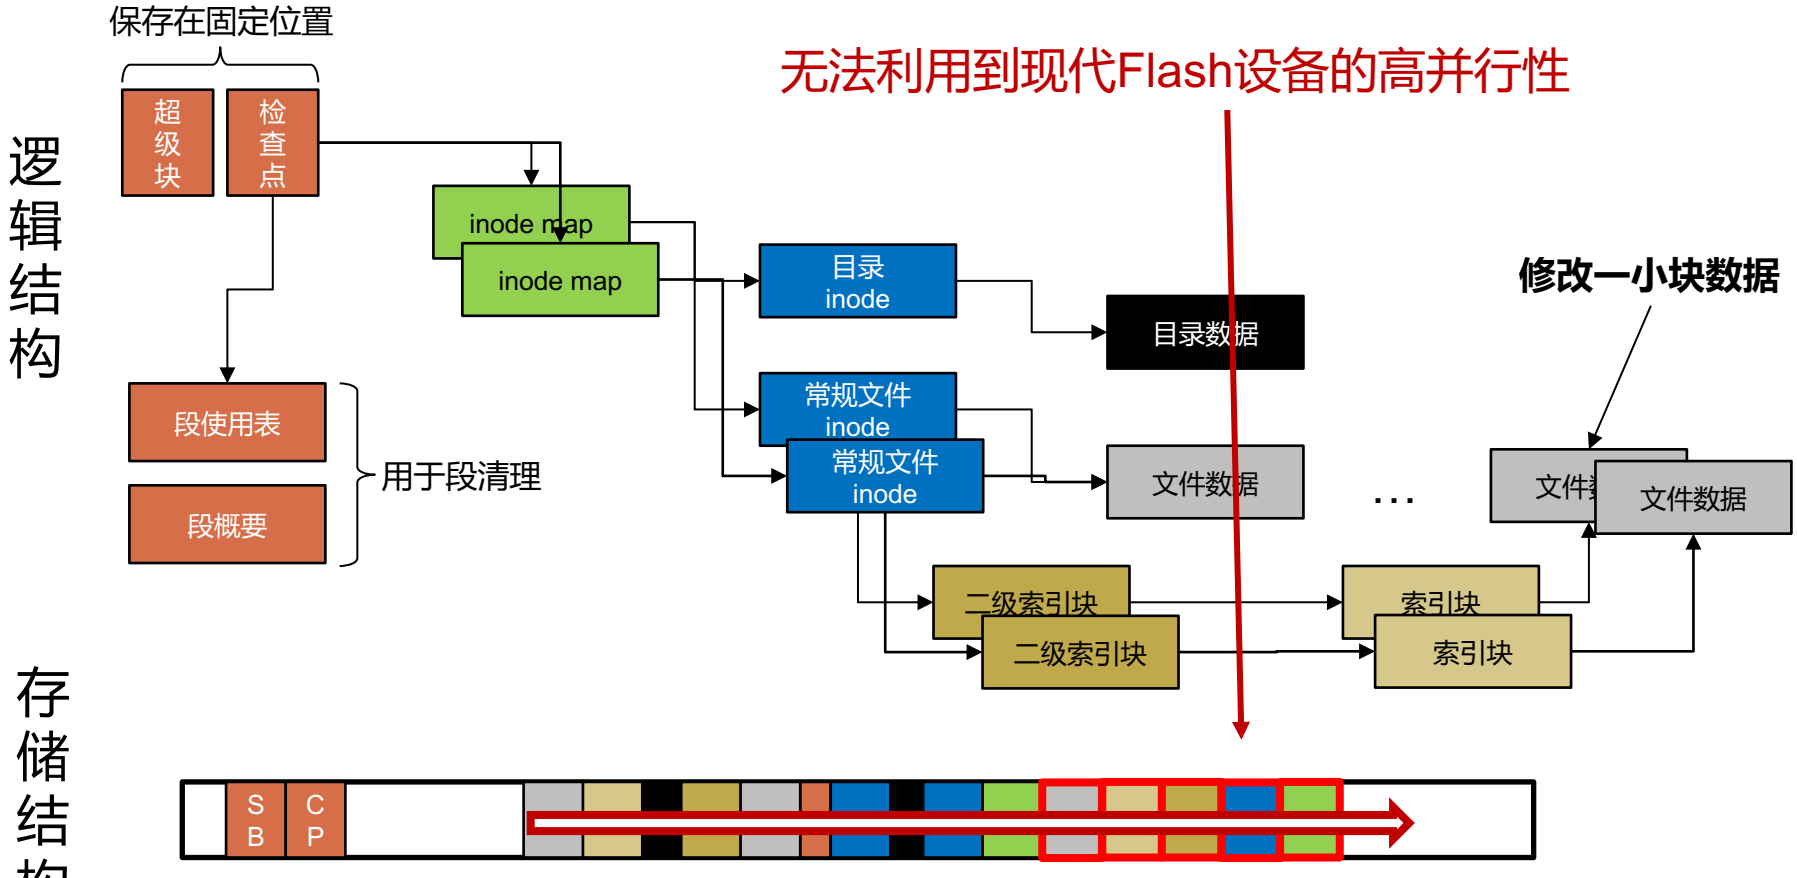

F2FS的改进1：NAT

- 引入一层 indirection：NAT（node地址转换表）
  - NAT：Node Address Table
  - 维护node号到逻辑块号的映射
  - Node号需转换成逻辑块号才能使用
- F2FS中的文件结构
  - 直接node：保存数据块的逻辑块号
  - 间接node：保存node号
    （相当于索引块）
  - 数据块：保存数据

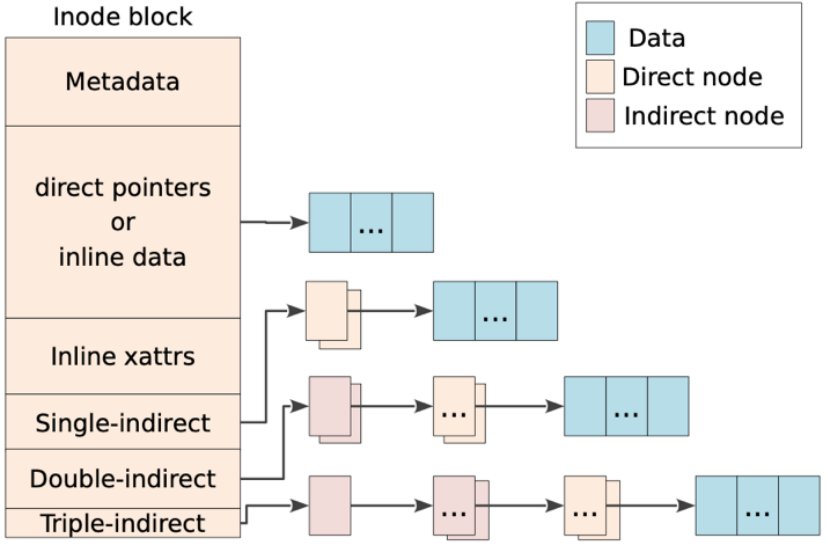

F2FS的改进1：NAT

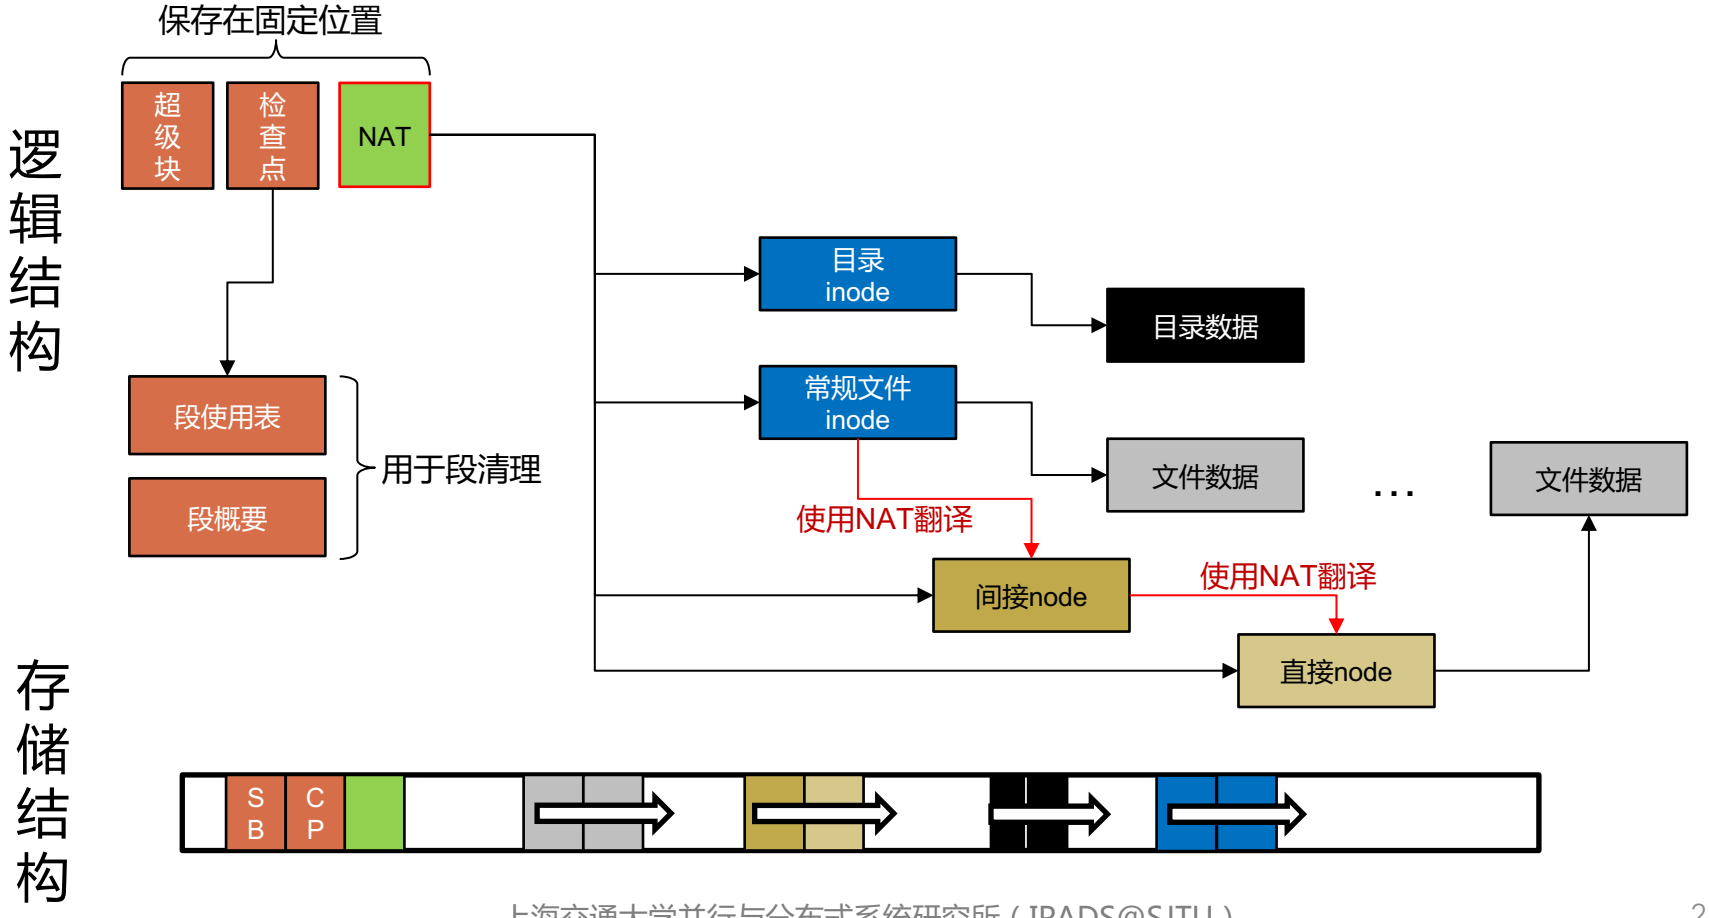

F2FS的改进1：NAT

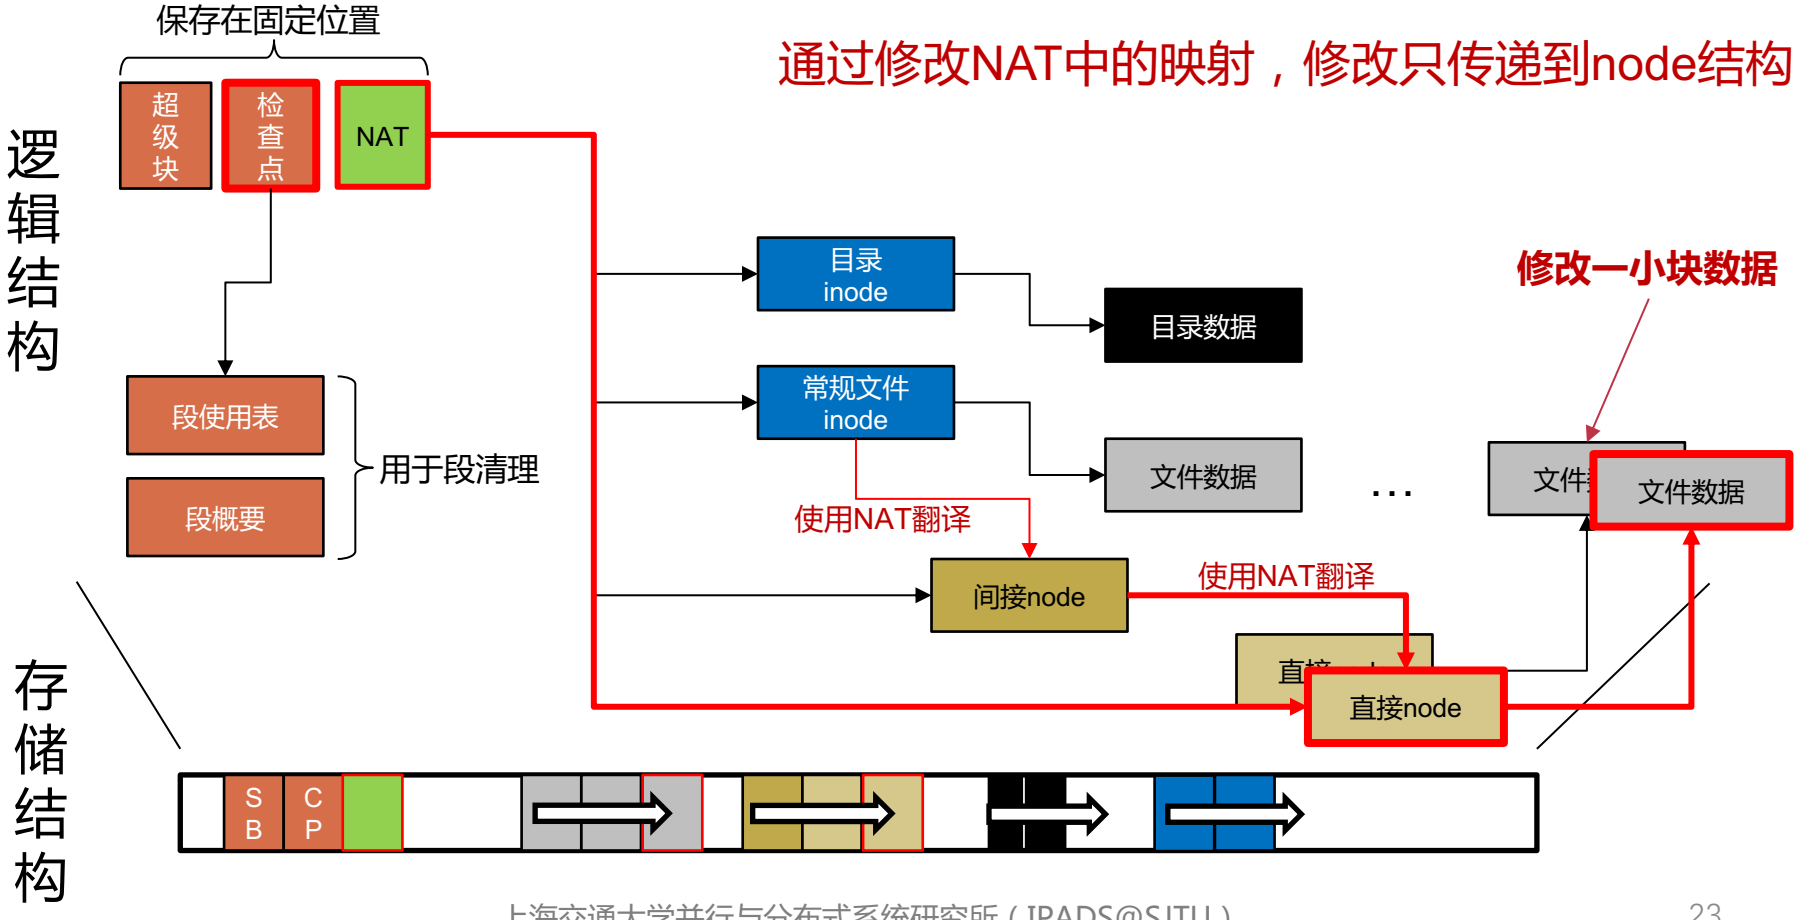

F2FS的改进2：多log并行写入

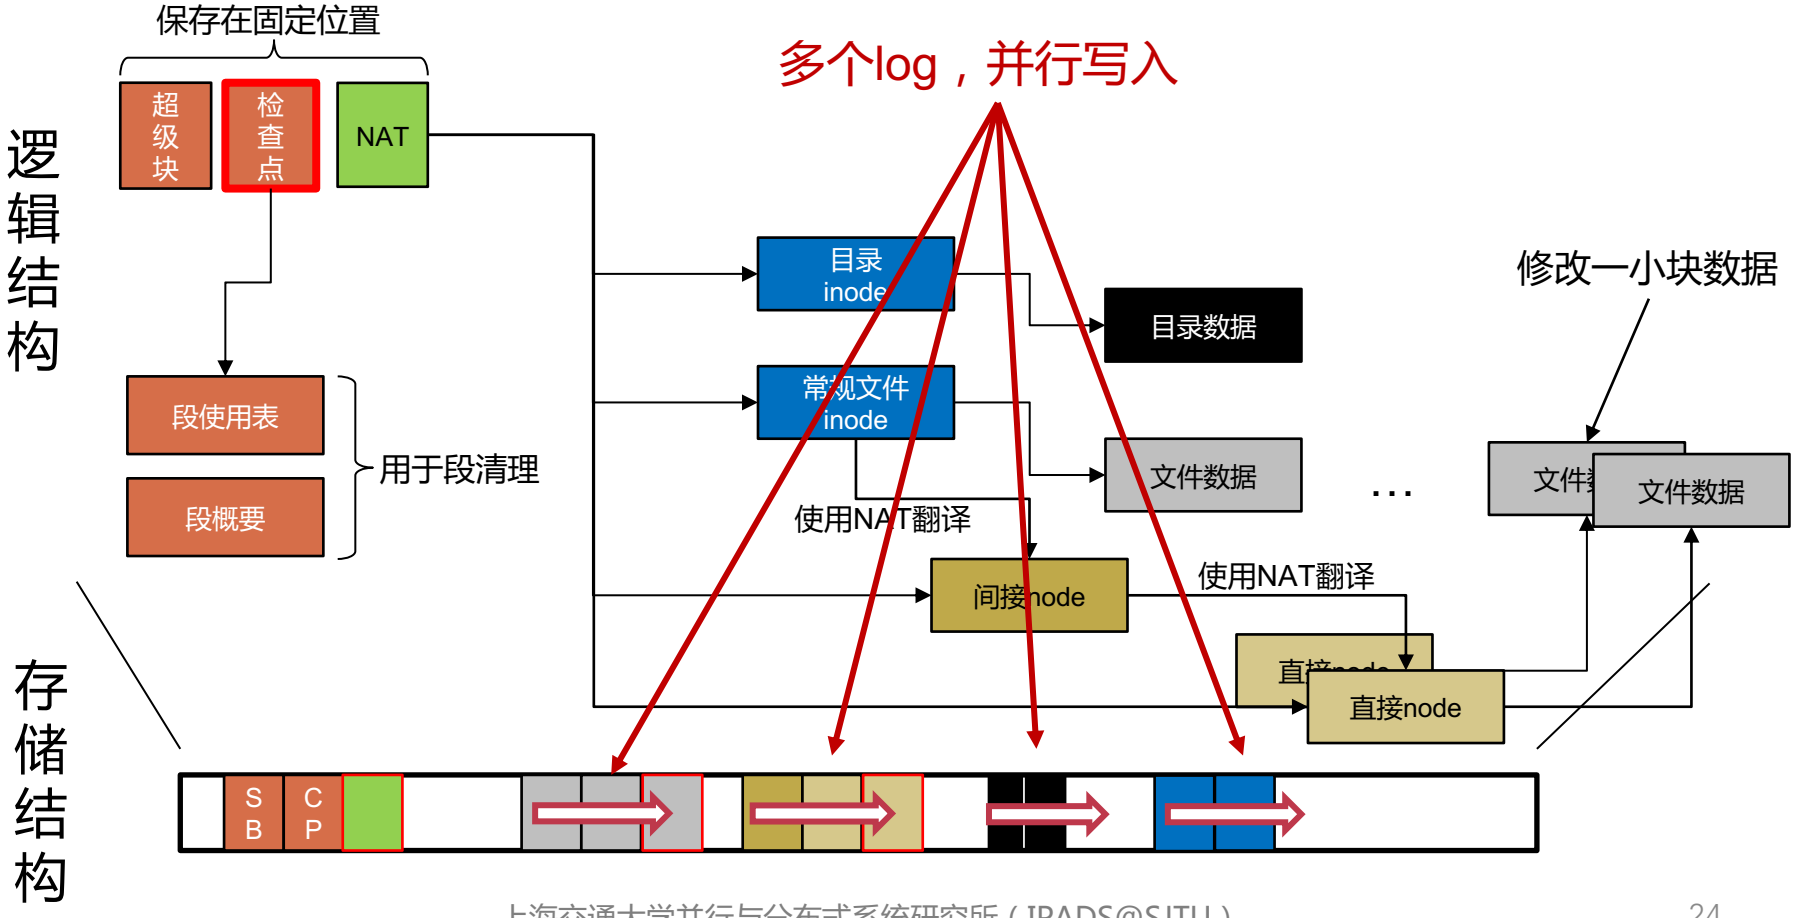

闪存友好的磁盘布局

- 组织层级
  - Block：4KB，最小的读写单位
  - Segment：2MB
  - Section：多个segment（垃圾回收/GC粒度）
  - Zone：多个section

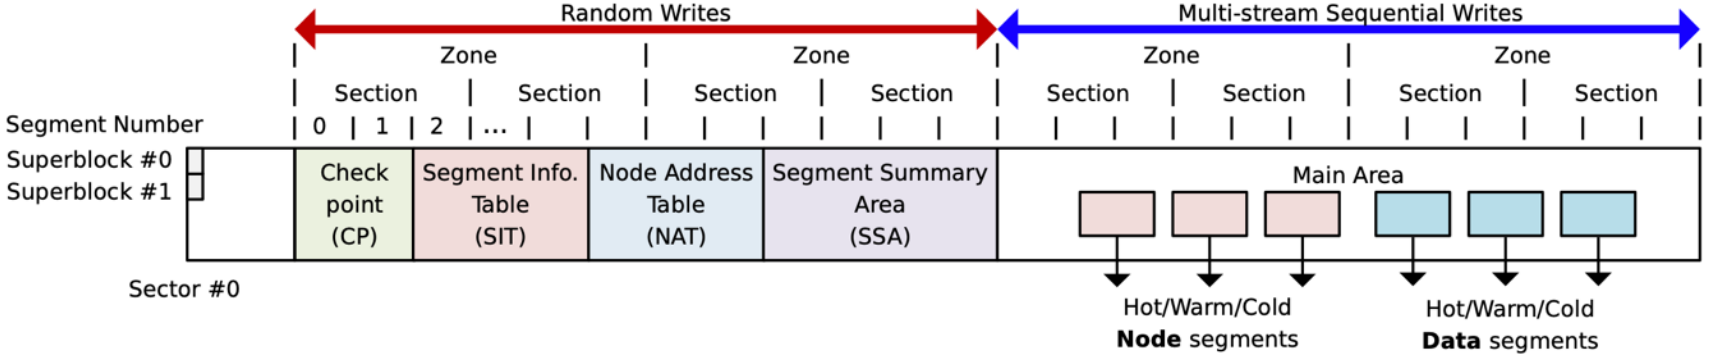

闪存友好的磁盘布局

- 系统元数据（随机写入）
  - 存放在一起：局部性更好
  - CP：检查点
  - SIT：段信息表
  - NAT：node地址转换表
  - SSA：段概要区域
- 数据区（多Log顺序写入）
  - 区分冷/温/热数据
  - 区分文件数据（data segment）与元数据（node segment）

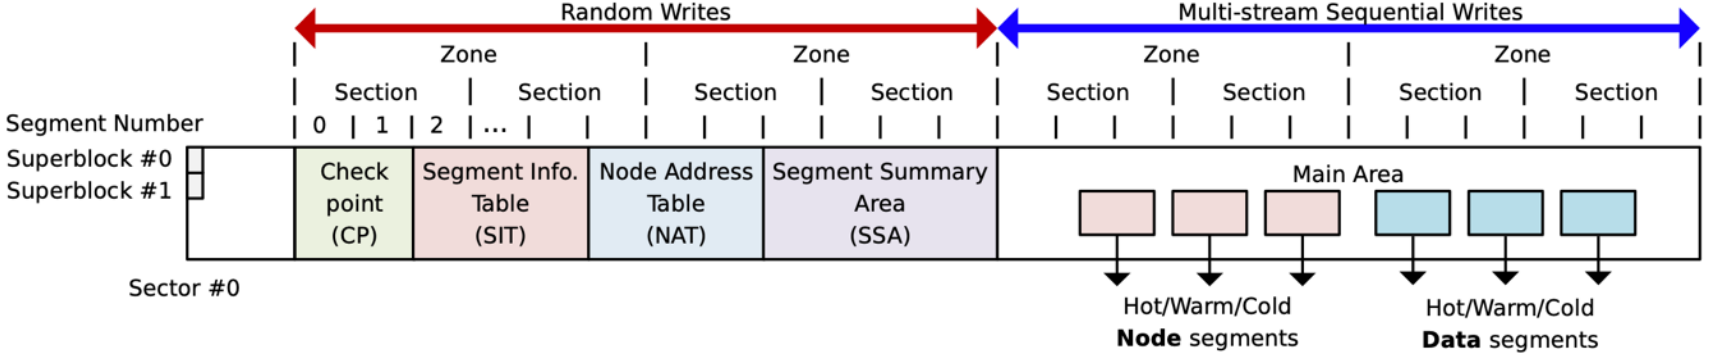

多Log写入

- 按热度将结构分类
  - 每个类型和热度对应一个log
  - 默认打开6个log
  - 用户可进一步配置

- 根据硬件信息可以进一步调整
  - 调整zone、section大小
  - 与硬件GC单元对齐等

类型	热度	对象
Node	热	目录的直接node块（包括inode块）
	温	常规文件的间接node块
	冷	间接node块
Data	热	存放目录项的数据块
	温	常规文件的数据块
	冷	被清理过程移动的数据块 用户指定的冷数据块 多媒体文件的数据块

清理（Cleaning）

回想一下：LFS为何要进行清理？

- 以section为粒度
  - 与硬件FTL的GC单位是对齐的

清理（Cleaning）

- 以section为粒度
  - 与硬件FTL的GC单位是对齐的
- 过程（与LFS类似）
  1. 选择需要清理的section
     - Greedy：选择有效块最少的section
     - Cost-effective：同时考虑数据修改时间
  2. 识别有效数据
  3. 有效数据拷贝到干净section
  4. 标记被清理的section为pre-free
     - 在下一次checkpoint之后被标记为free

思考一下：为什么不直接标记为free？

自适应日志

- 文件系统使用一段时间后，干净section不足，需要频繁清理
- F2FS动态调整数据段的日志方法
  - 干净section充足时，使用常规方法
    - 日志写到干净section中
    - 没有干净section时需要进行清理操作
  - 干净section不足时，使用 threaded logging
    - 使用脏段中无效的块
    - 避免清理操作
    - 但会产生一些随机写

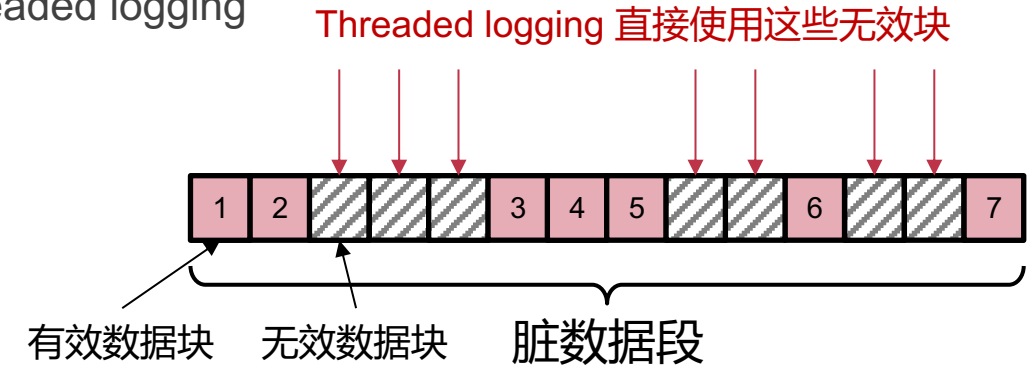

检查点

回想一下：为何要需要检查点？

- 检查点、NAT、SIT各有两份
- 检查点中保存有NAT和SIT的日志，避免NAT和SIT的频繁更新
- 恢复时回滚到最近的检查点

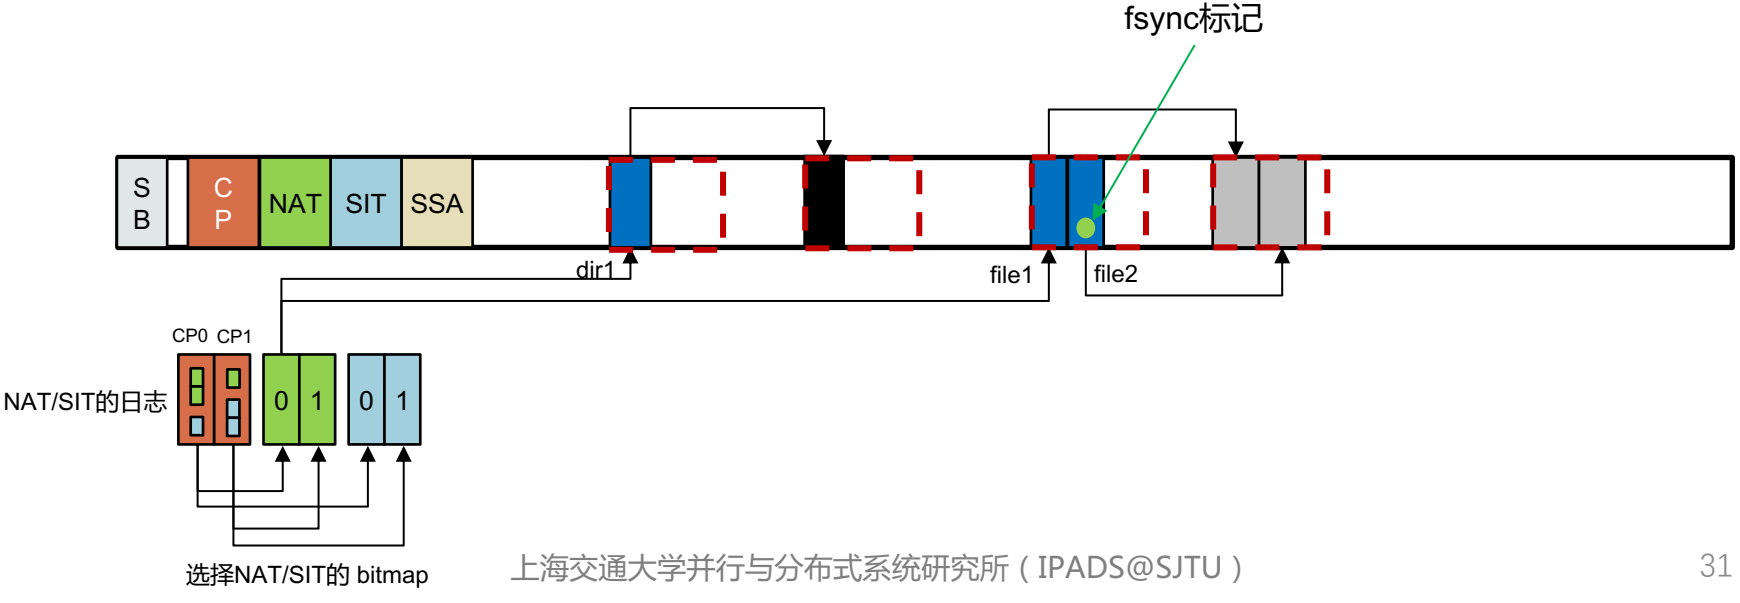

崩溃与恢复

1. 创建dir1和file1

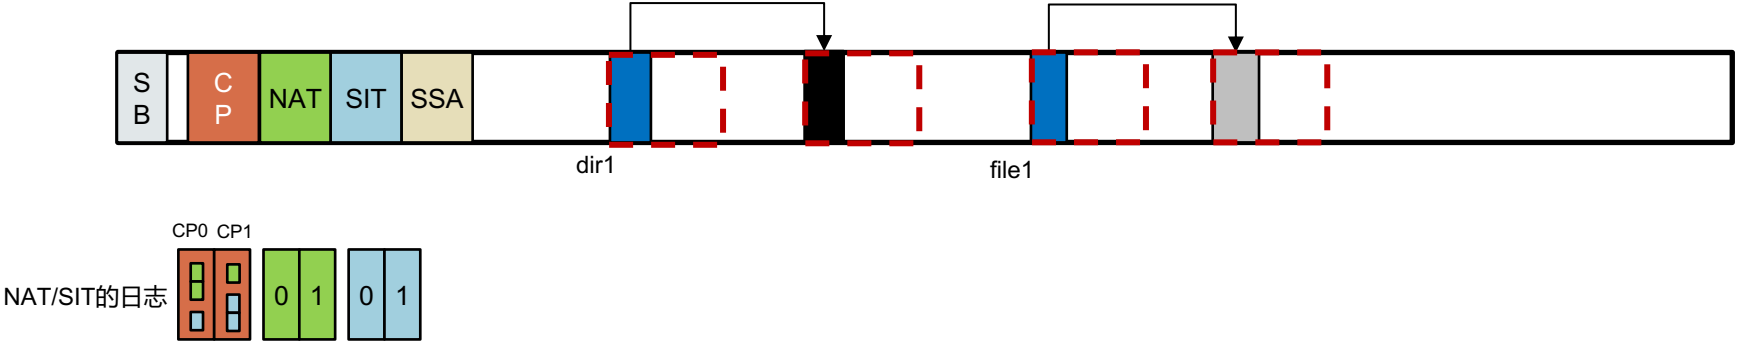

崩溃与恢复

1. 创建dir1和file1
2. 创建检查点0

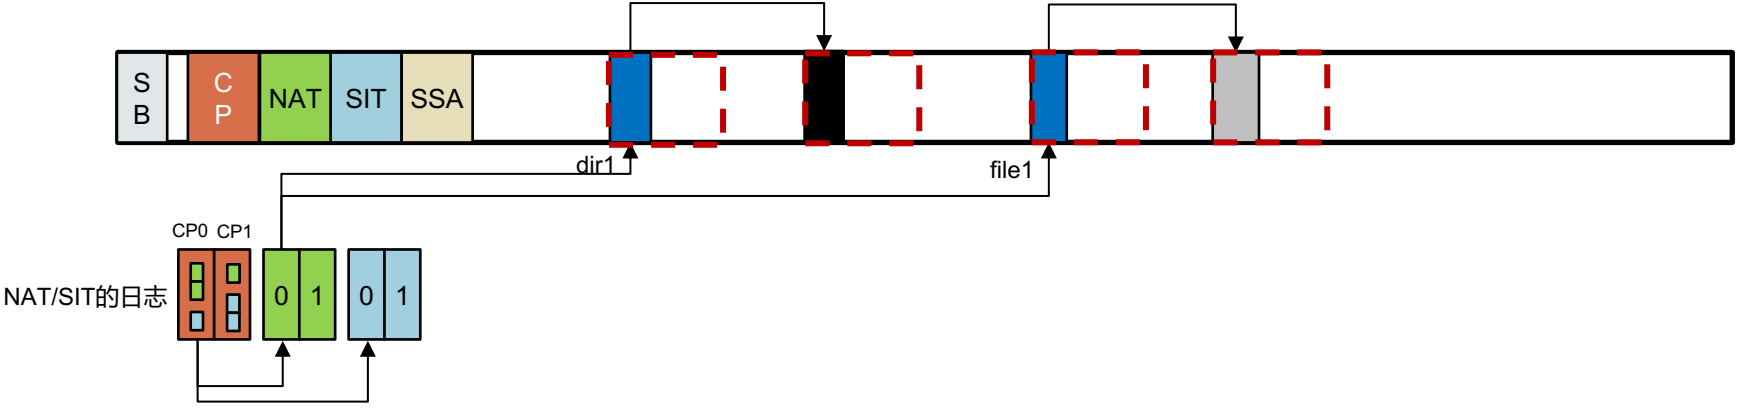

崩溃与恢复

1. 创建dir1和file1
2. 创建检查点0
3. 创建和更新file2，并执行fsync完毕

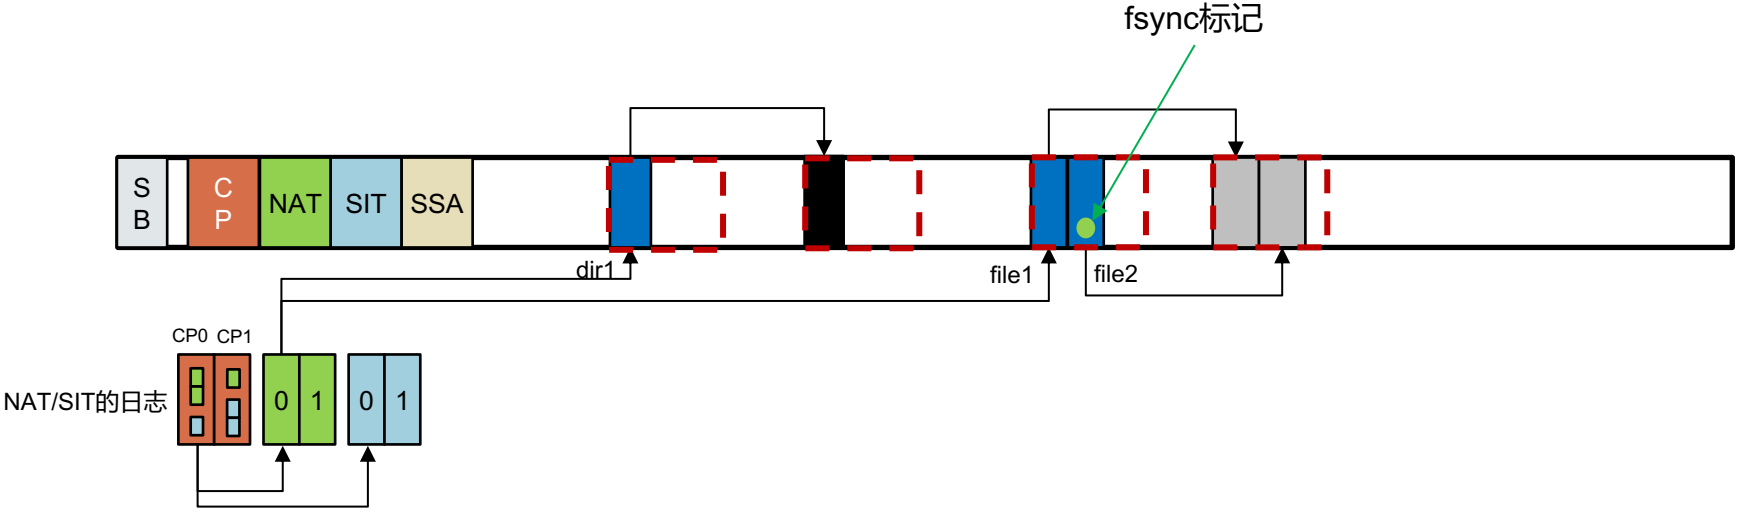

崩溃与恢复

1. 创建dir1和file1
2. 创建检查点0
3. 创建和更新file2，并执行fsync完毕
4. 发生意外掉电

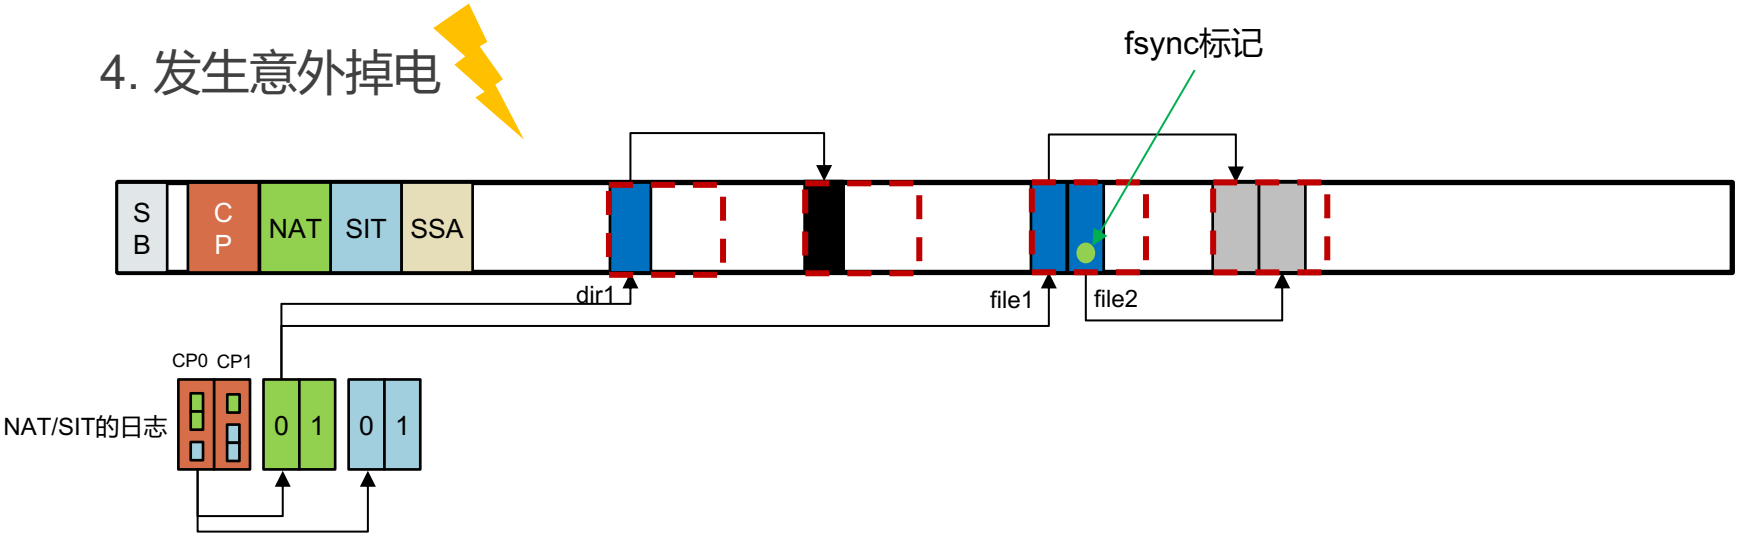

崩溃与恢复：回滚（roll-back）

1. 创建dir1和file1
2. 创建检查点0
3. 创建和更新file2，并执行fsync完毕
4. 发生意外掉电

恢复：
1. 回滚到最近的检查点（CP0）
   - 可找到文件dir1和file1

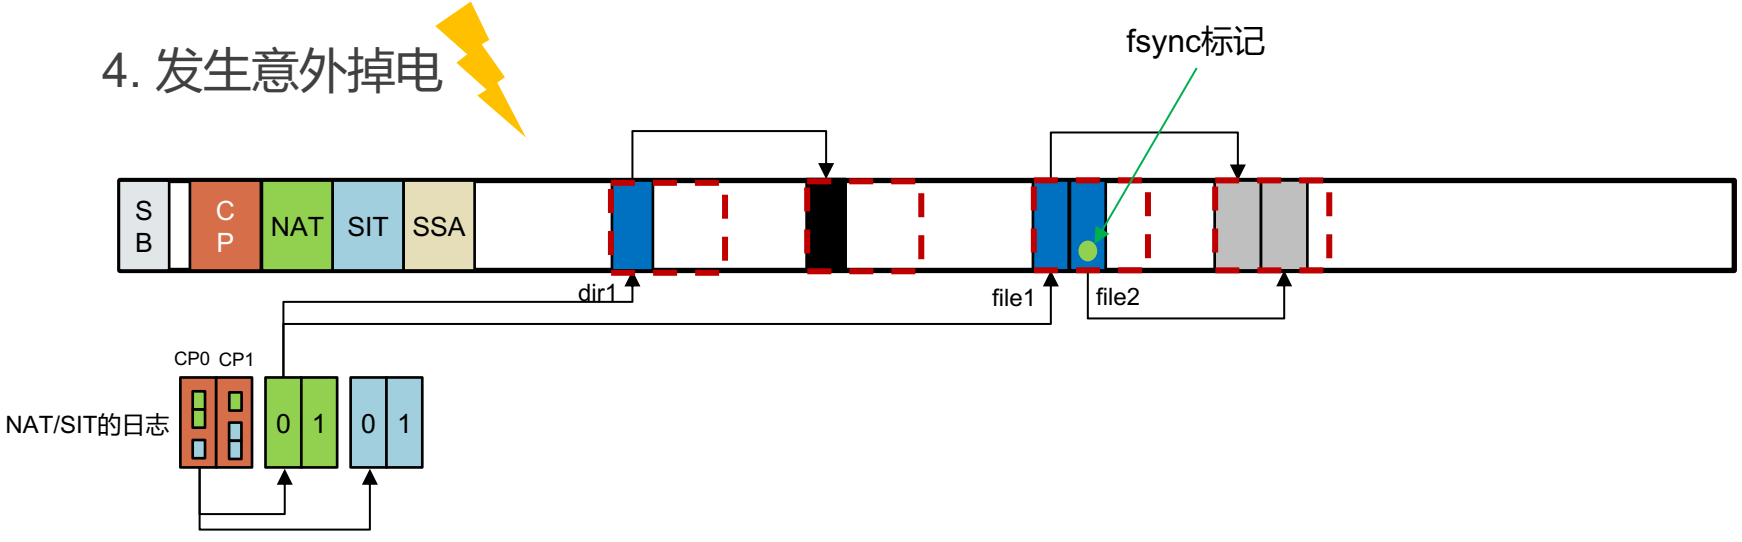

崩溃与恢复：前滚（roll-forward）

1. 创建dir1和file1
2. 创建检查点0
3. 创建和更新file2，并执行fsync完毕
4. 发生意外掉电

恢复：

1. 回滚到最近的检查点（CP0）
   - 可找到文件dir1和file1
2. 前滚恢复fsync过的file2

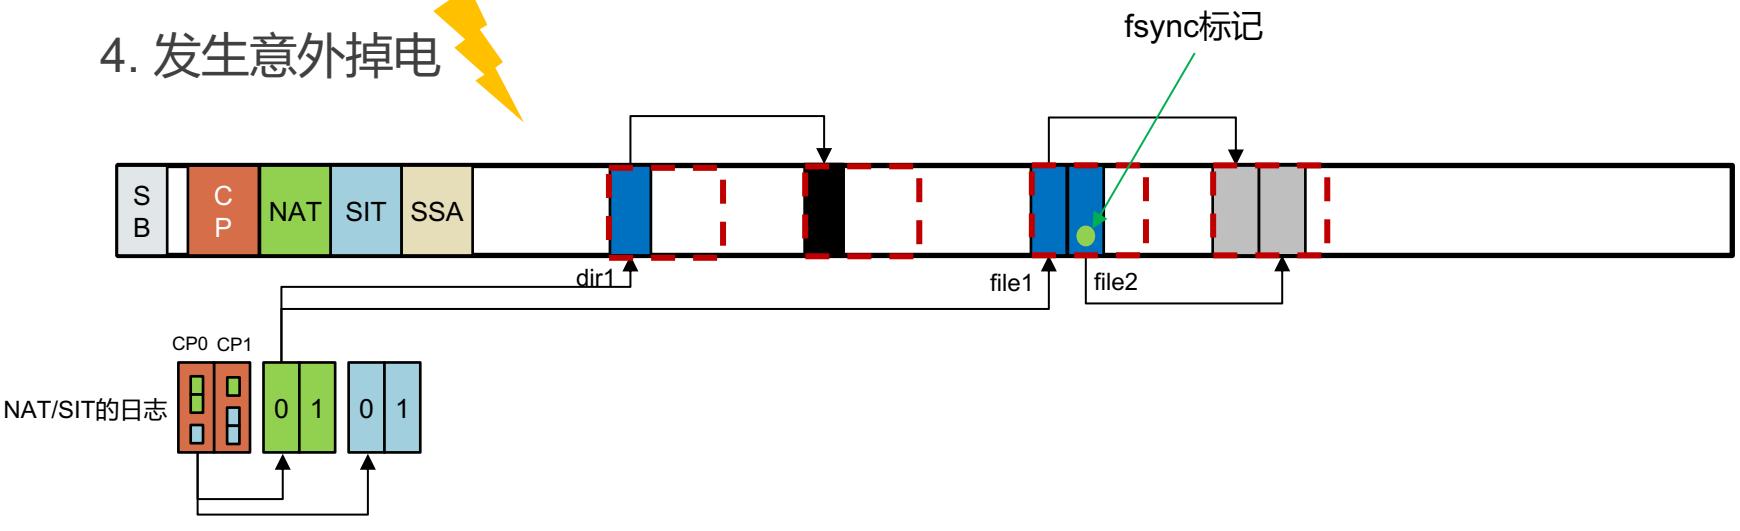

前滚：fsync()的处理

- 原有LFS
  - 创建新的检查点
- F2FS
  - 无需创建新的检查点
  - 持久化文件数据块和直接node，并在直接node上附带fsync标记
  - 前滚：恢复检查点之后fsync过的数据

前滚：恢复检查点之后fsync过的数据

- 前滚恢复
  1. 查找带有fsync标记的直接node
  2. 对于每个直接node，对比其中的数据块指针，识别新旧数据块
  3. 更新SIT，标记旧的数据块为无效
  4. 根据直接node中新数据块的记录，更新NAT和SIT
  5. 创建新的检查点

Shingled Magnetic Recording (SMR) Disk

瓦式磁盘

He, Weiping, and David HC Du. *Smart: An approach to shingled magnetic recording translation.* In *FAST' 17.*

瓦式磁盘

- 传统磁盘密度难以提升
  - 写磁头的宽度难以减小
- 瓦式磁盘将磁道重叠，提升存储密度
  - 减小读磁头的宽度

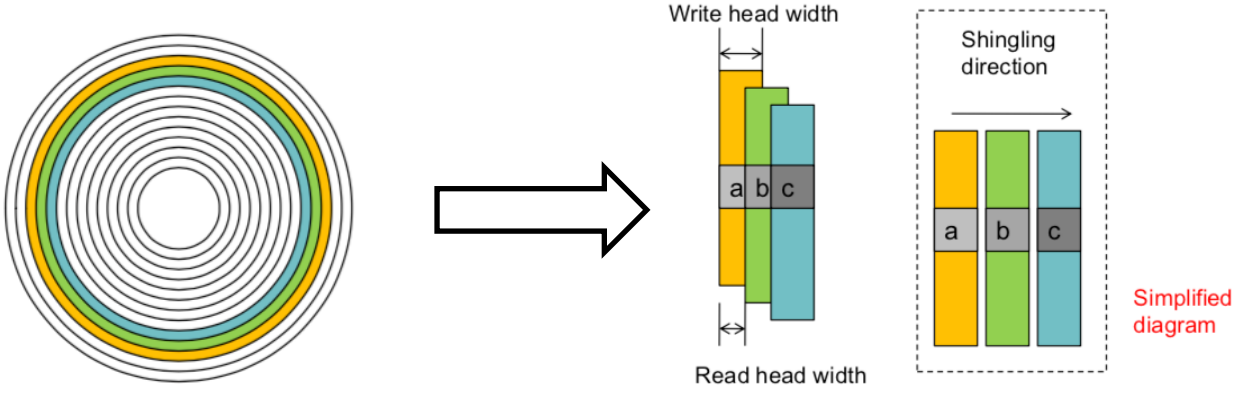

瓦式磁盘的问题：随机写

- 随机写会覆盖后面磁道的数据
  - 只能顺序写入

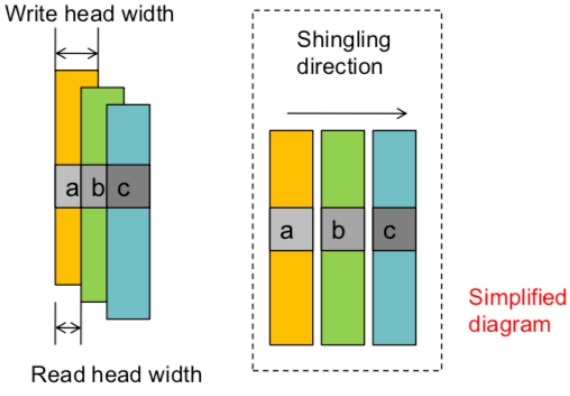

瓦式磁盘的问题：随机写

- 随机写会覆盖后面磁道的数据
  - 只能顺序写入
- 避免整个磁盘只能顺序写入
  - 磁盘划分成多个Band，Band间增大距离
  - 每个Band内必须顺序写入

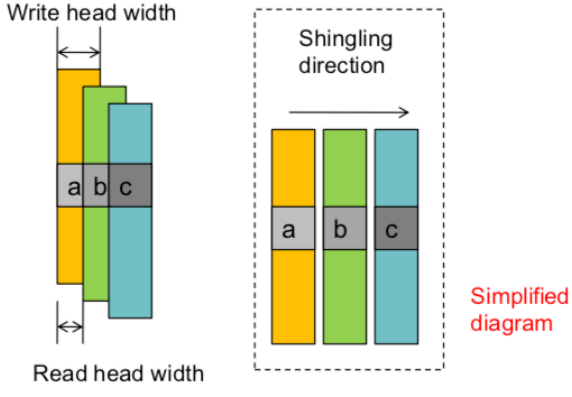

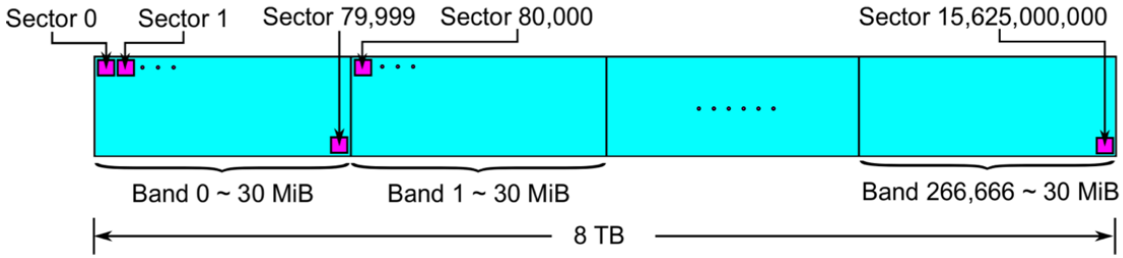

Logical view of an 8 TB statically mapped drive-managed SMR disk

Band内随机写怎么办？

- Band大小（30MB） > 块设备读写粒度（4KB）

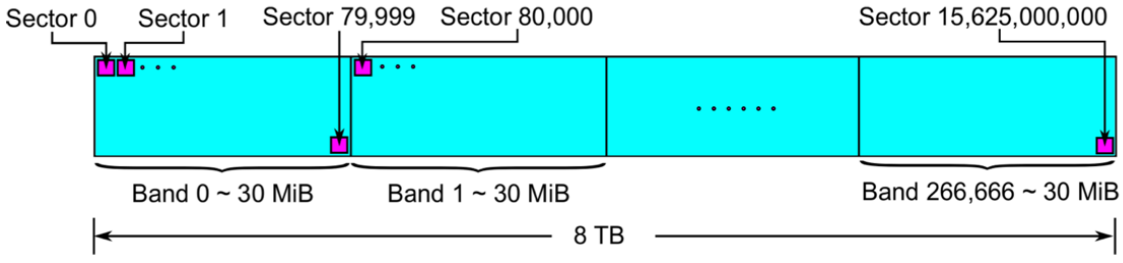

Logical view of an 8 TB statically mapped drive-managed SMR disk

方法一：多次拷贝

- 修改Band X中的4KB数据
  1. 找到空闲Band Y
  2. 从Band X的数据拷贝到Band Y，拷贝时将4KB修改写入
  3. 将Band Y中的数据拷贝回Band X
- 4KB随机写 → 120MB访问

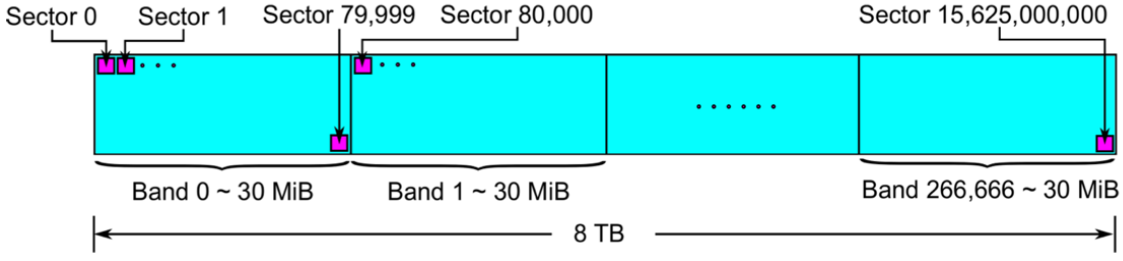

Logical view of an 8 TB statically mapped drive-managed SMR disk

方法二：缓存+动态映射

- 大容量持久缓存
  - 在磁盘头部预留的区域，磁道不重叠，可随机写入
  - 给固件（STL）单独使用，外部不可见
- 动态映射：Shingle Translation Layer (STL)
  - 从外部（逻辑）地址到内部（物理）地址的映射

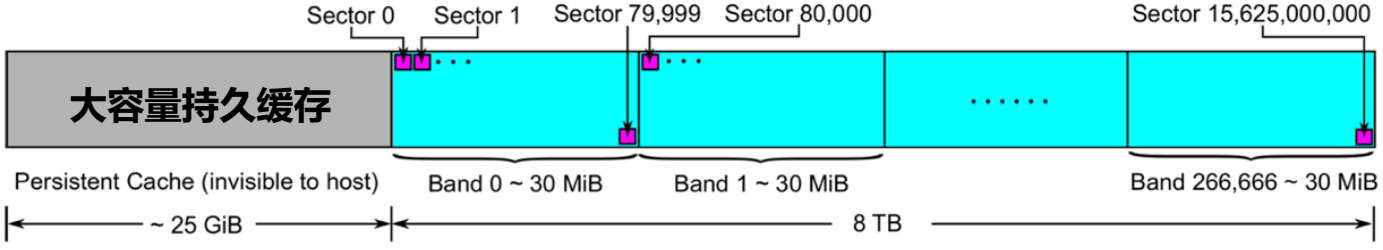

Logical view of an 8 TB statically mapped drive-managed SMR disk

方法二：缓存+动态映射

- 修改Band X中的4KB数据
  1. 将修改写入缓存，标记Band X为dirty
  2. 修改STL映射（让原位置指向持久化缓存）
  3. 空闲时，根据缓存内容，将 dirty Band进行清理
- 4KB随机写 → 修改4KB缓存

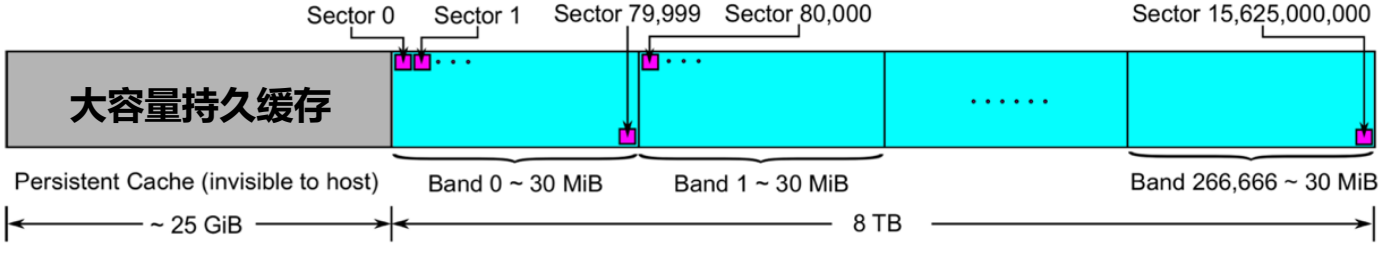

Logical view of an 8 TB statically mapped drive-managed SMR disk

瓦式磁盘种类

SMR磁盘种类	接口	随机写处理方法
Drive-managed SMR (DM-SMR)	普通块设备接口	固件进行缓存和清理
Host-aware SMR (HA-SMR)	特殊指令接口	固件进行缓存和清理
Host-managed SMR (HM-SMR)	特殊指令接口	必须顺序写，随机写请求被拒绝

无需修改软件，可直接替换传统磁盘！

DM-SMR上使用Ext4

- 当随机写入时，Ext4吞吐量非常低！

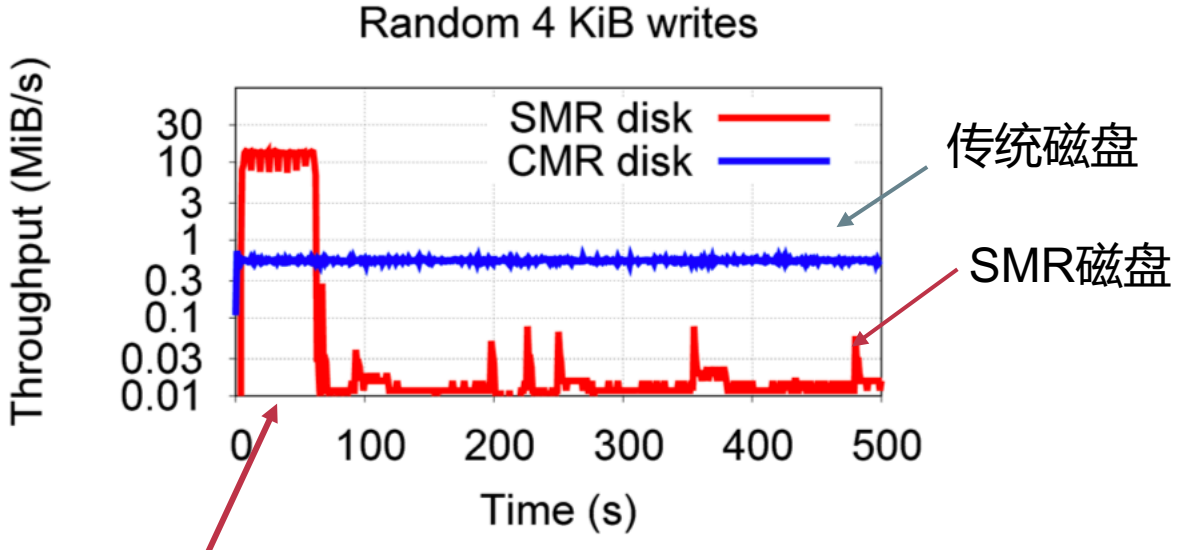

思考一下：为何这段时间内SMR磁盘上吞吐量很高？

如何改进Ext4来适应瓦式磁盘呢？

- **以DM-SMR磁盘为目标**
  - HM-SMR和HA-SMR需要文件系统的设计新的文件系统
  - 在成熟的Ext4上优化：消除元数据写回造成的随机写入
- **修改量小**
  - Ext4 + journaling 代码 ~50,000 行
  - 仅仅修改 ~40 行代码，新文件中添加 ~600 LOC 代码
- **效果显著**
  - 元数据修改较少时(<1%)，在SMR磁盘上有1.7-5.4倍性能提升
  - 有大量元数据修改时，在SMR和普通磁盘上，有2-13倍性能提升
  - 特定场景下达到40倍性能提升

Aghayev, Abutalib, Theodore Ts'o, Garth Gibson, and Peter Desnoyers. *Evolving ext4 for shingled disks.* In *FAST '17*.

观察：持久缓存对吞吐量的影响

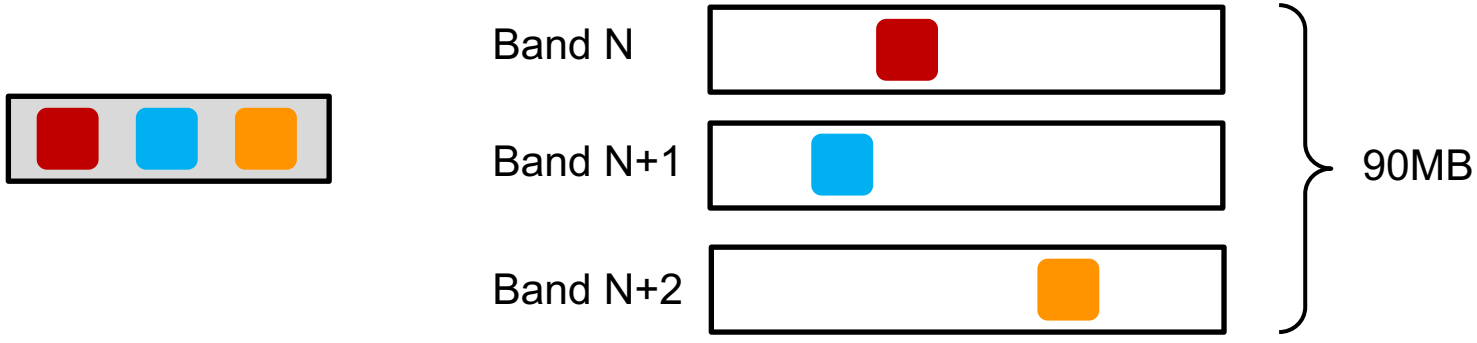

若持久化缓存中的写比较分散，清理时需要清理大量Band
假设清理1个Band需要1秒，吞吐量为1个随机写/秒

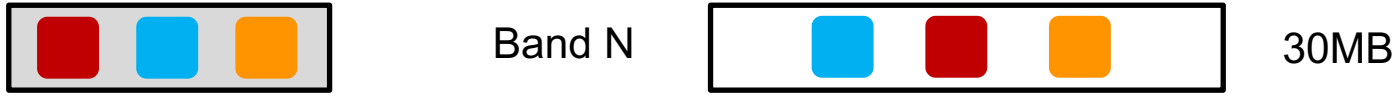

若三个随机写在一个Band中，则只需清理一个Band；吞吐量为3个随机写/秒

随机写的跨度→ 脏band数量 → 清理时的工作量 → 吞吐量

然而：Ext4的元数据非常分散

- Ext4使用块组（flex_bg）将文件系统分成多个区域
  - 每个块组前16MB用来保存元数据，其余保存数据
- 每次数据修改产生多处元数据的修改
- 8TB分区上有4,000个块组，元数据分散在4,000个Band！
- 分散的元数据随机写 → 脏band数量↓ → 清理工作的负担↓ → 吞吐量↑

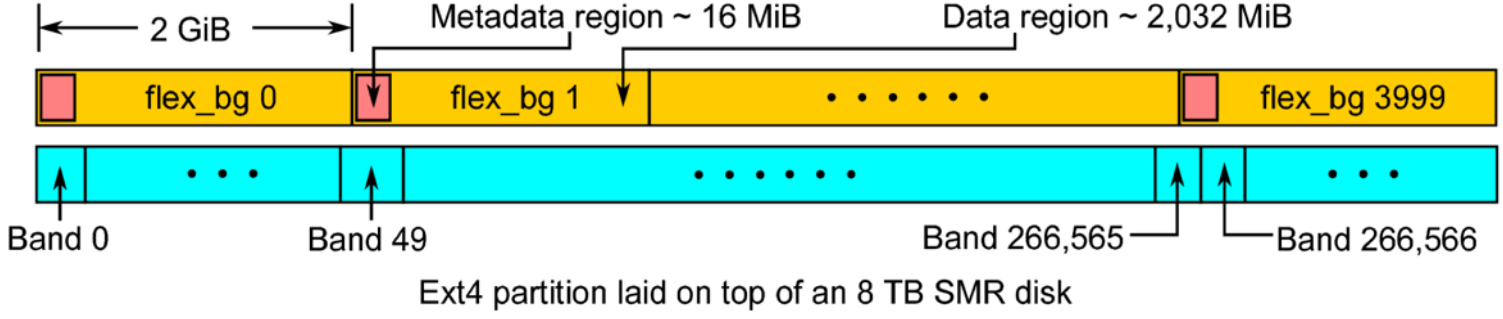

Ext4 partition laid on top of an 8 TB SMR disk

回顾：Ext4上的元数据写回

- Ext4使用JBD2记录元数据日志
  - 128MB的日志区域
  1. JBD2首先将元数据写入日志区域*J*，标记元数据为脏
  2. 脏元数据在日志提交后被写回到其应有位置*S*

频繁的元数据写回，造成大量的分散随机写，降低吞吐量

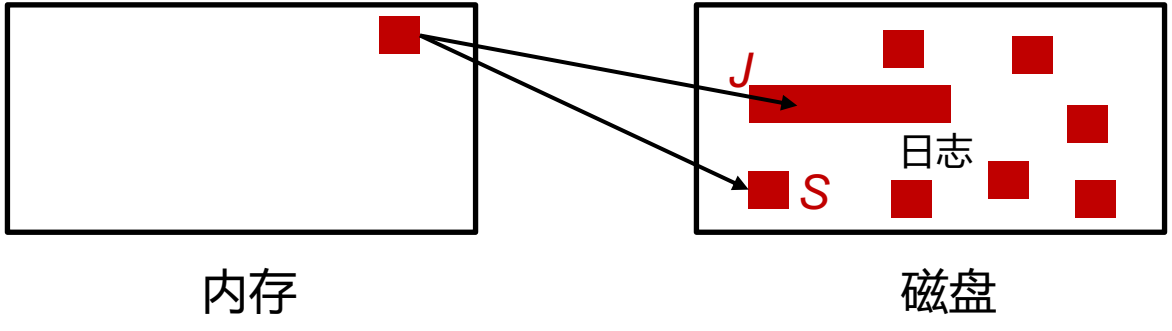

回到问题：Ext4上的元数据分散

- 修改磁盘布局需要大规模修改Ext4
  - 人力成本、新增Bug、破坏原有功能……
- 怎么办？
- 引入Indirection：以LFS形式增加一个元数据缓存

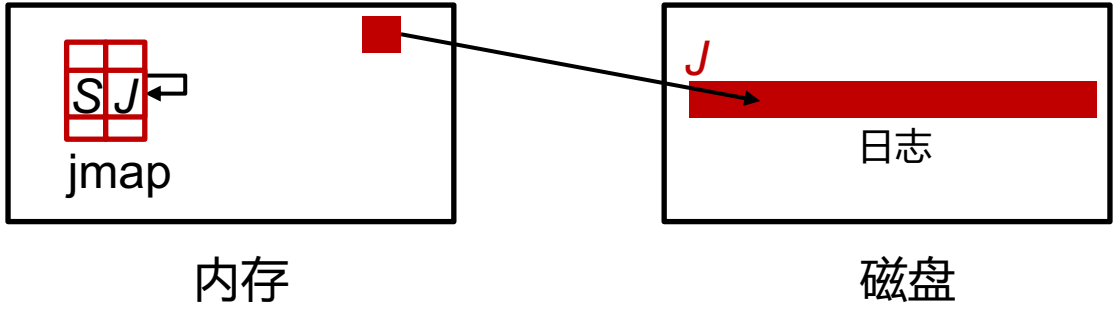

解决方法：以LFS形式增加一个元数据缓存

- 以LFS形式维护10GB日志空间作为元数据缓存
  1. JBD2首先将元数据写入日志区域*J*，将元数据标记为clean（无需写回）
  2. JBD2在内存中的jmap中将*S*映射到*J*
- Indirection: 元数据访问需要通过jmap进行一次地址转换

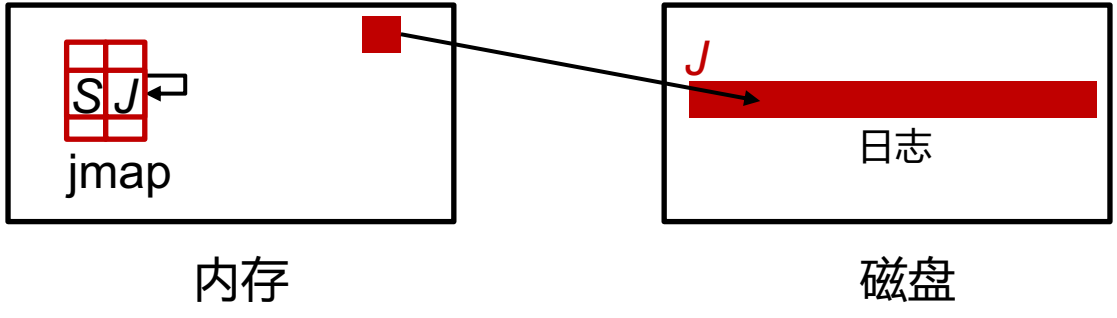

日志满了怎么办？

- 日志空间清理
  - 无效的元数据（被新修改覆盖过的元数据）可以直接被回收
  - 对于冷元数据，可将其写回到Ext4中其原本的位置S
  - 热元数据继续保留在日志中
- 挂载FS时，读取日志，恢复出jmap

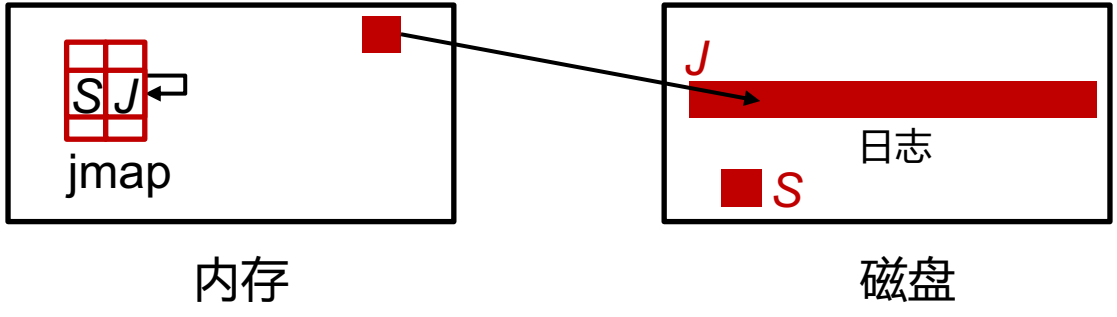

实现：对Ext4的修改

修改的~40行代码：将请求转给jbd2

```
-   submit_bh(READ | REQ_META | REQ_PRIO, bh);
+   jbd2_submit_bh(journal, READ | REQ_META | REQ_PRIO, bh, __func__);
```

新增文件：jmap.c（维护jmap）

```
+void jbd2_submit_bh(journal_t *journal, int rw, struct buffer_head *bh,
+                     const char *func)
+{
+           sector_t fsblk = bh->b_blocknr;
+           ...
+           je = jbd2_jmap_lookup(journal, fsblk, func);
+           if (!je) {
+                       submit_bh(rw, bh);
+                       return;
+           }
+           ...
+           logblk = je->mapping.logblk;
+           read_block_from_log(journal, rw, bh, logblk);
+}
```

拦截Ext4对block的请求

查找jmap

不在jmap中，直接访问磁盘对应block

根据jmap中记录的地址，在日志中读取block

实现：对Ext4的修改

新增文件：cleaner.c（维护10GB日志空间）

```
+static void do_clean_batch(struct work_struct *work)
+{
+           struct cleaner_ctx *ctx;
+           handle_t *handle = NULL;
+           int nr_live, err;
+           ...
+           nr_live = find_live_blocks(ctx);
+           if (nr_live == 0)
+                       goto done;
+           ...
+           read_live_blocks(ctx, nr_live);
+
+           handle = jbd2_journal_start(ctx->journal, nr_live);
+
+           ...
+           attach_live_blocks(ctx, handle, nr_live);
+
+           err = jbd2_journal_stop(handle);
+done:
+           ...
+}
```

将10GB日志空间的元数据写回到其在Ext4中的原本位置

扫描日志中有效块，并加入ctx中临时保存

新的JBD2原子更新

将ctx中的有效块加入到JBD2原子更新中

结束JBD2原子更新

Non-volatile Memory (NVM)

非易失性内存

非易失性内存

如果内存里面的数据重启后还在，岂不是很棒？

思考一下：会有哪些好处？

NVDIMM

- 在内存条上加上Flash和超级电容
  - 平时数据在DRAM中；断电后转移到Flash中持久保存

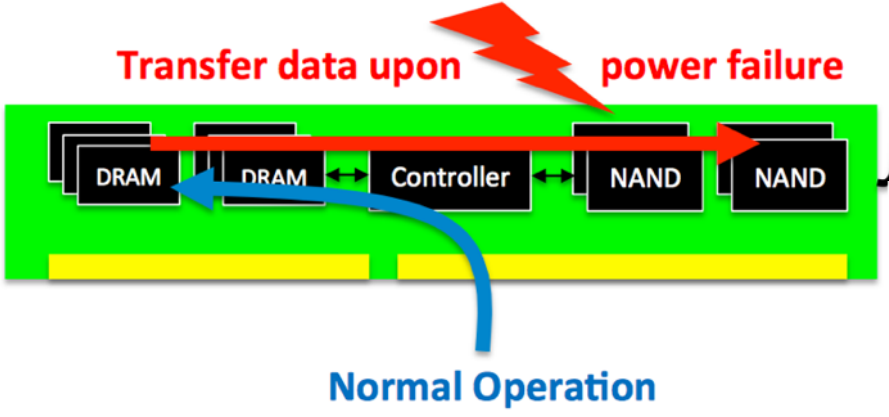

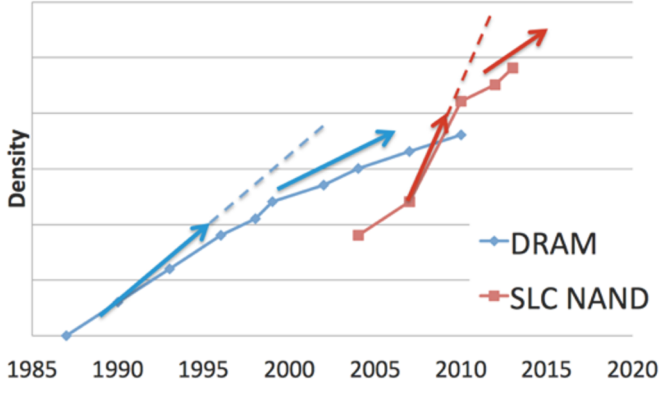

- 容量很难再提升

Intel Optane DC Persistent Memory

- ✓ 内存接口
- ✓ 字节寻址
- ✓ 持久保存数据
- ✓ 高密度 (512GB/DIMM)
- ✓ 需要磨损均衡，但耐磨度比NAND好10倍
- ✓ 比DRAM慢十倍以内，比NAND快1000倍

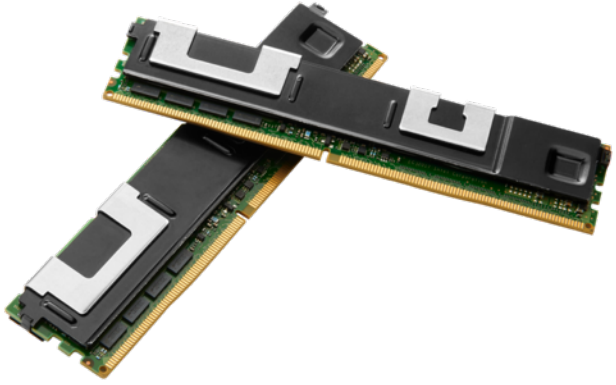

Figure from Intel

非易失性内存带来的新问题

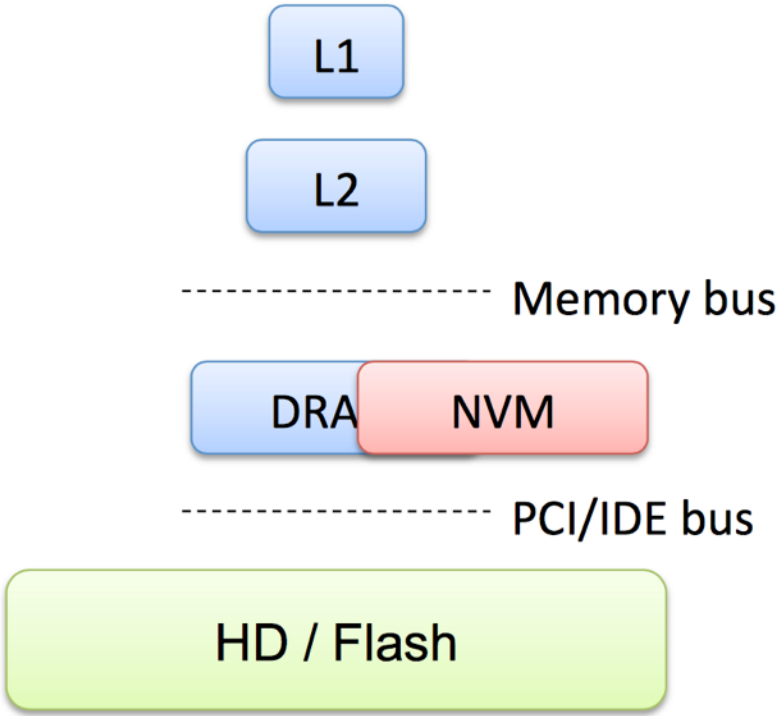

	DISK	NVM
数据缓存位置	内存	CPU 缓存
写回	软件控制	硬件控制

Some figures and slides from https://research.cs.wisc.edu/sonar/tutorial/

内存写入顺序

- Writeback模式的CPU缓存
  - 提升性能
  - 会打乱内存写入顺序

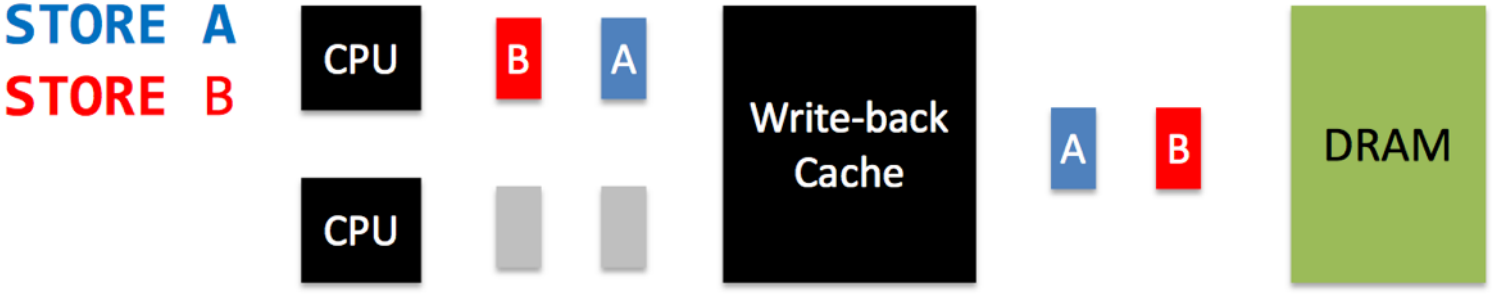

非易失性内存写入顺序

- 考虑持久性，写入顺序很重要

```
STORE data[0] = 0xFOOD
STORE data[1] = 0xBEEF
STORE valid = 1
```

非易失性内存写入顺序

- 考虑持久性，写入顺序很重要

```
STORE data[0] = 0xFOOD
STORE data[1] = 0xBEEF
STORE valid = 1
```

错误的写入顺序在恢复时将垃圾数据视为有效数据！

思考🤔：有哪些解决方法？

- 关闭CPU缓存？
- 使用Write-through模式的缓存？
- 每次写入后刷除整个缓存？

使用CLFLUSH保证顺序

- 使用CLFLUSH指令将数据逐出缓存，以保证顺序

```
STORE data[0] = 0xFOOD
STORE data[1] = 0xBEEF
CLFLUSH data[0]
CLFLUSH data[1]
STORE valid = 1
```

- 但是CLFLUSH
  - 顺序执行，阻塞CPU流水线
  - 会将cacheline无效化

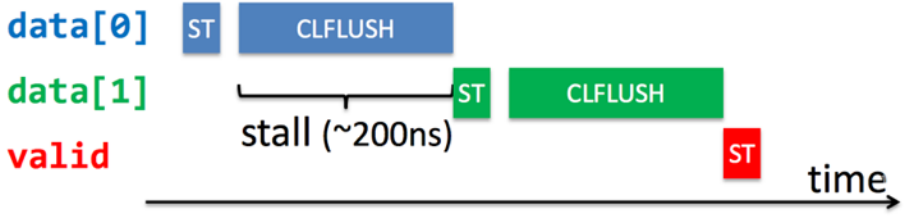

Intel x86 拓展指令集

- CLFLUSHOPT
  - 可并行执行的CLFLUSH
  - 需要sfence保证顺序

```
STORE data[0] = 0xFOOD
STORE data[1] = 0xBEEF
CLFLUSHOPT data[0]
CLFLUSHOPT data[1]
SFENCE // explicit ordering point
STORE valid = 1
```

Implicit orderings

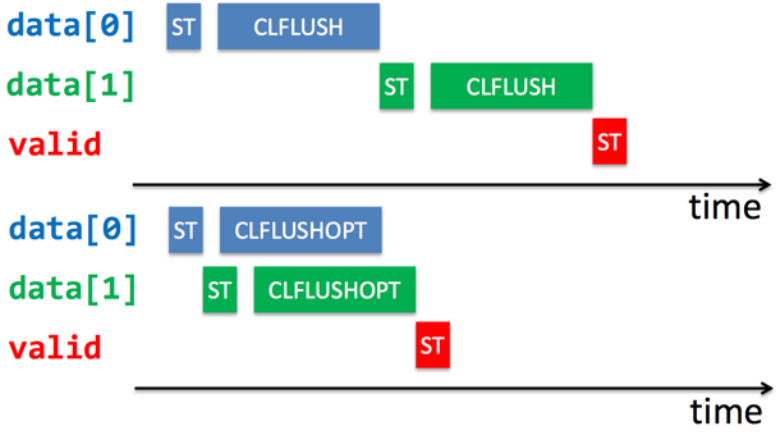

- CLWB
  - CLFLUSHOPT的基础上，不会将cacheline无效化

举例：NVM上的写时复制

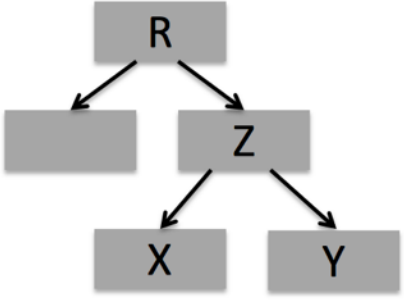

举例：NVM上的写时复制

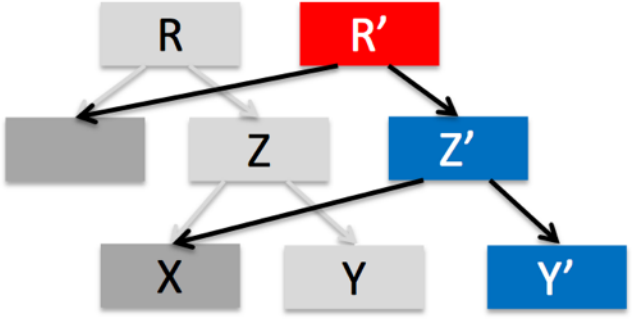


```
STORE Y’
STORE Z’
CLWB Y’
CLWB Z’
SFENCE
STORE R’
CLWB R’
```

举例：NVM上的写时复制

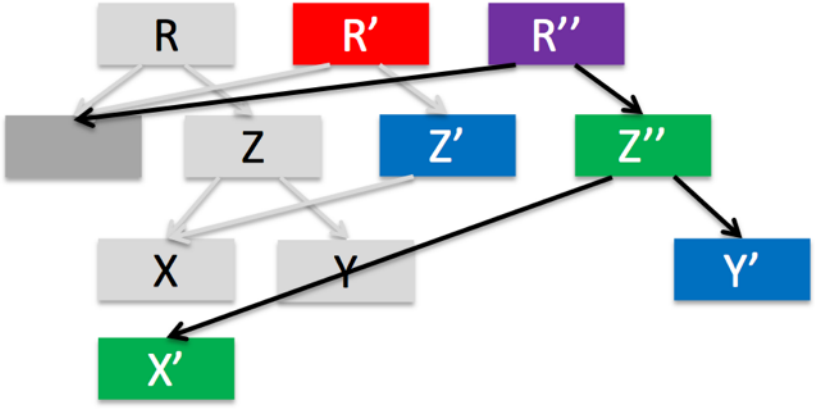


```
STORE Y’
STORE Z’
CLWB Y’
CLWB Z’
SFENCE
STORE R’
CLWB R’
SFENCE
STORE X’
STORE Z’’
CLWB X’
CLWB Z’’
SFENCE
STORE R’
CLWB R’
```

Non-volatile Memory File System

非易失性内存文件系统

非易失性内存改变存储栈

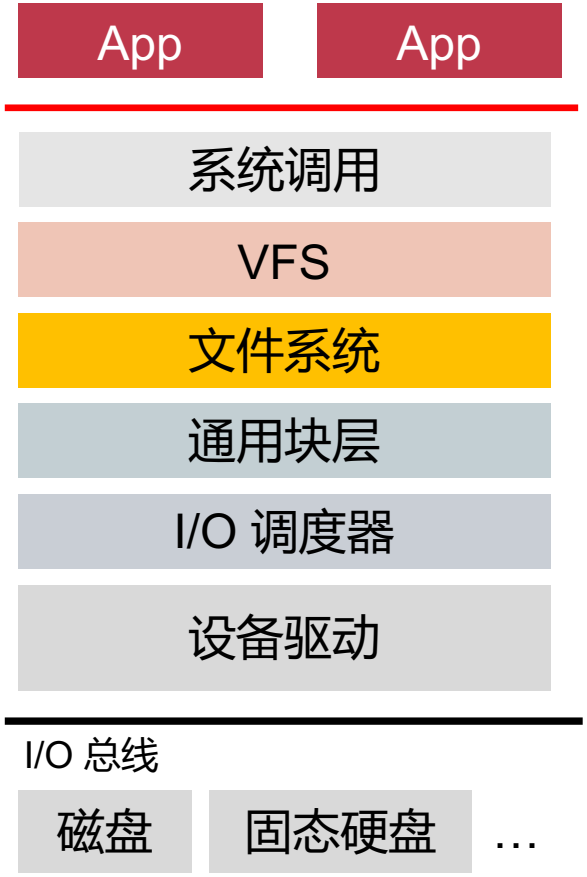

非易失性内存改变存储栈

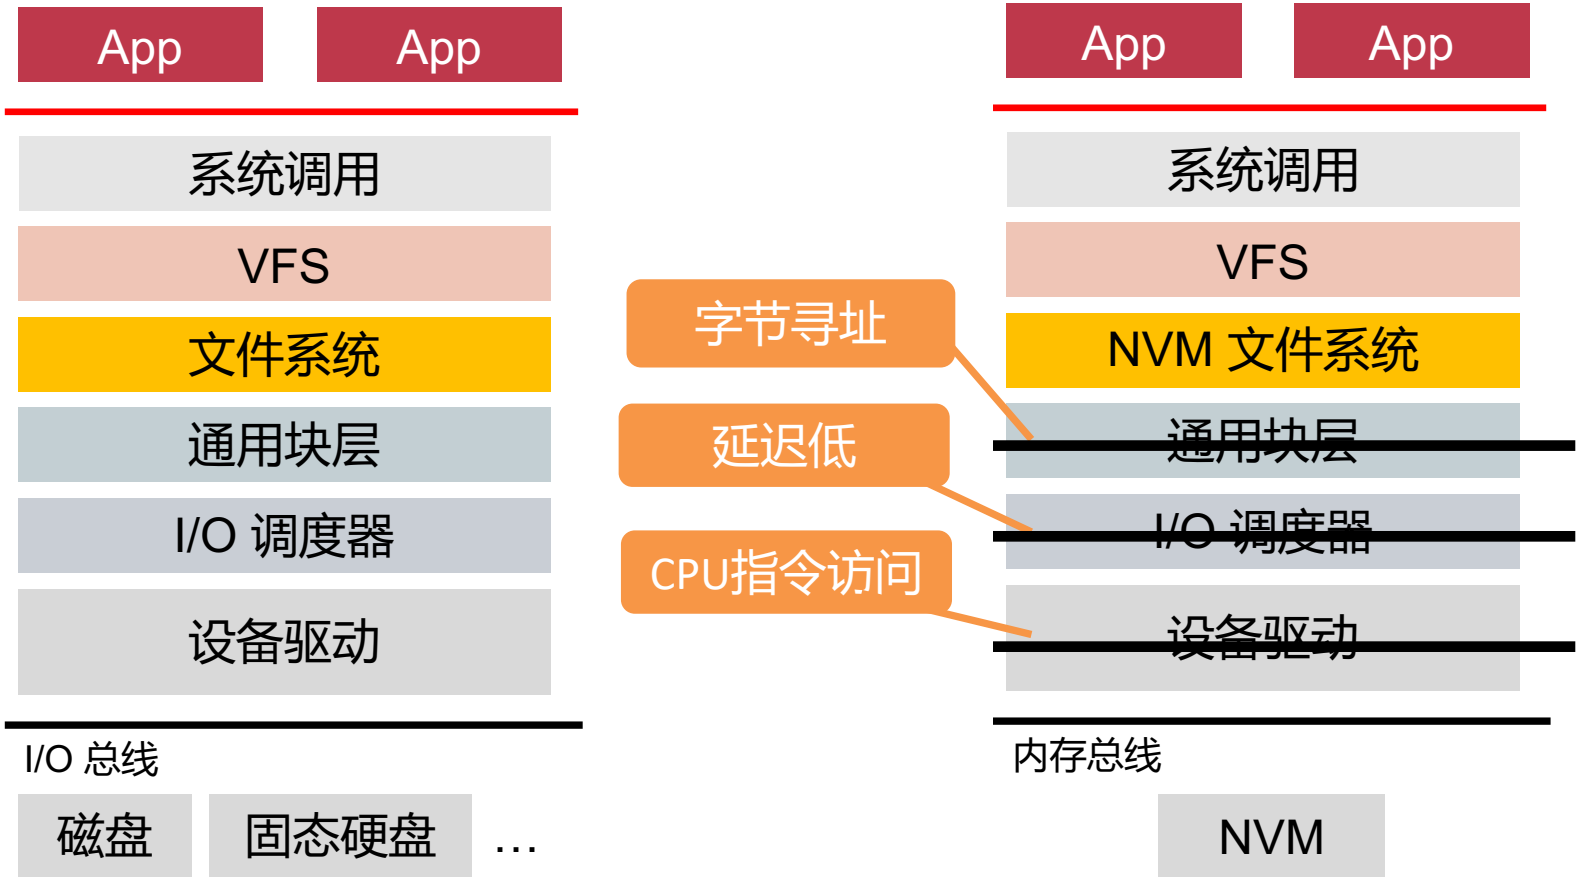

一致性技术与非易失性内存文件系统

- 原子指令：ALL
- 写时复制：BPFS[*SOSP '09*], PMFS[*EuroSys '14*], NOVA[*FAST '16*]
- 日志 (Journaling): PMFS, NOVA
- Log-structured: NOVA
- Soft updates: SoupFS[*USENIX ATC '17*]

PMFS

- 为NVM和体系结构优化
  - 多种原子更新技术
- 允许应用直接访问NVM
  - DAX mmap
- Wild writes保护

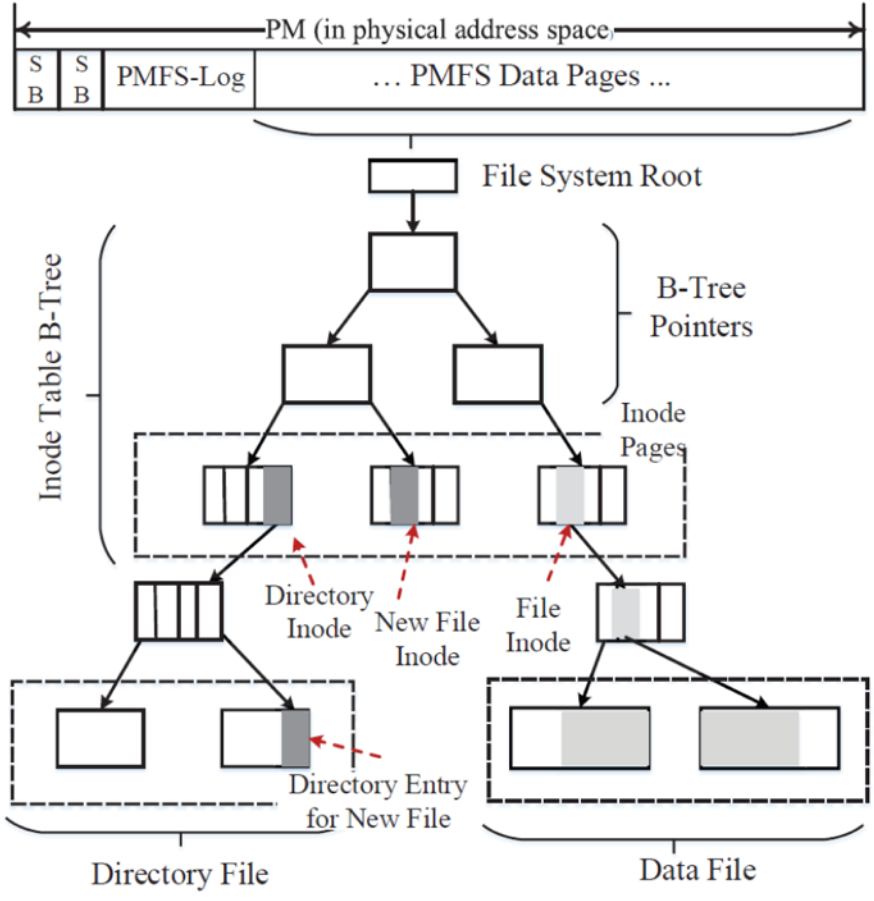

Figure 3: PMFS data layout

Many slides from the PMFS talk

PMFS中的一致性保证

- 现有方法
  - 写时复制 (Shadow Paging)
  - 日志
  - Log-structured updates
- NVM专有的方法
  - 原子指令更新

用于文件数据更新

用于元数据更新，如inode

用于小修改

拓展的原子指令更新

- 8字节更新
  - CPU原本就支持8字节的原子更新
  - 更新inode的访问时间
- 16字节更新
  - 使用 *cmpxchg16b* 指令
  - 同时更新inode中的文件大小和修改时间
- 64字节更新
  - 使用硬件事务内存（HTM）
  - 更新inode中的多个数据

让应用直接访问NVM

- DAX（direct access）
  - 文件mmap时
  - 通过建立页表映射
  - 将数据页映射给应用

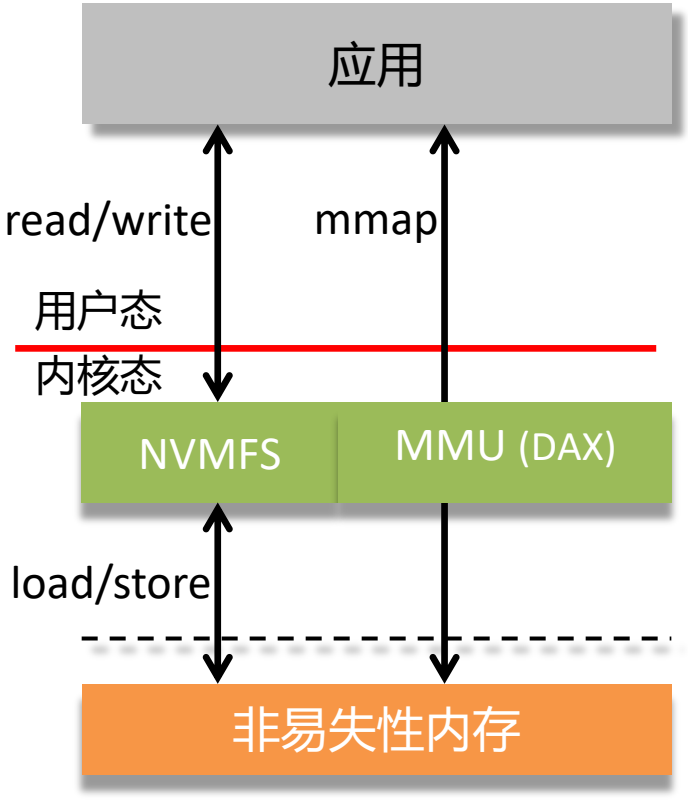

防止NVM上的wild writes

- 程序Bug产生的wild writes会破坏NVM上的数据
- Supervisor Mode Access Protection (SMAP)
  - 防止内核错误地修改用户内存
- Write windows (PMFS提出)
  - 挂载时，NVM映射为只读
  - 写入时，CR0.WP临时设置为0，内核可以修改只读映射

	User	Kernel
User	Process Isolation	SMAP
Kernel	Privilege Levels	Write windows

Table 2: Overview of PM Write Protection

下次课

- 设备与设备驱动