IPADS INSTITUTE OF PARALLEL AND DISTRIBUTED SYSTEMS

上海交通大學 SHANGHAI JIAO TONG UNIVERSITY

网络

陈海波 / 夏虞斌

上海交通大学并行与分布式系统研究所

https://ipads.se.sjtu.edu.cn

版权声明

- 本内容版权归**上海交通大学并行与分布式系统研究所**所有
- 使用者可以将全部或部分本内容免费用于非商业用途
- 使用者在使用全部或部分本内容时请注明来源：
  - 内容来自：上海交通大学并行与分布式系统研究所+材料名字
- 对于不遵守此声明或者其他违法使用本内容者，将依法保留追究权
- 本内容的发布采用 Creative Commons Attribution 4.0 License
  - 完整文本：https://creativecommons.org/licenses/by/4.0/legalcode

回顾：宏内核vs微内核的驱动

- **宏内核**
  - 驱动在内核态
  - 优势：性能更好
  - 劣势：容错性差

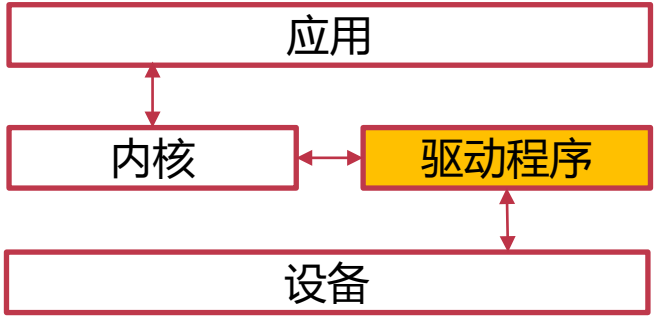

- **微内核**
  - 驱动在用户态
  - 优势：可靠性好
  - 劣势：性能开销（IPC）

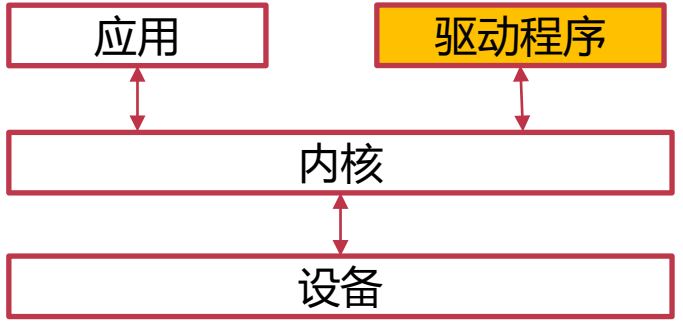

回顾：设备驱动模型

- **设备驱动模型**
  - 提供标准化的数据结构和接口
  - 将驱动开发简化为对数据结构的填充和实现
  - 方便操作系统统一组织和管理设备
- **Linux上下半部**
  - 上半部：尽量快，提高对外设的响应能力
  - 下半部：将中断的处理推迟完成

回顾：sysfs

- 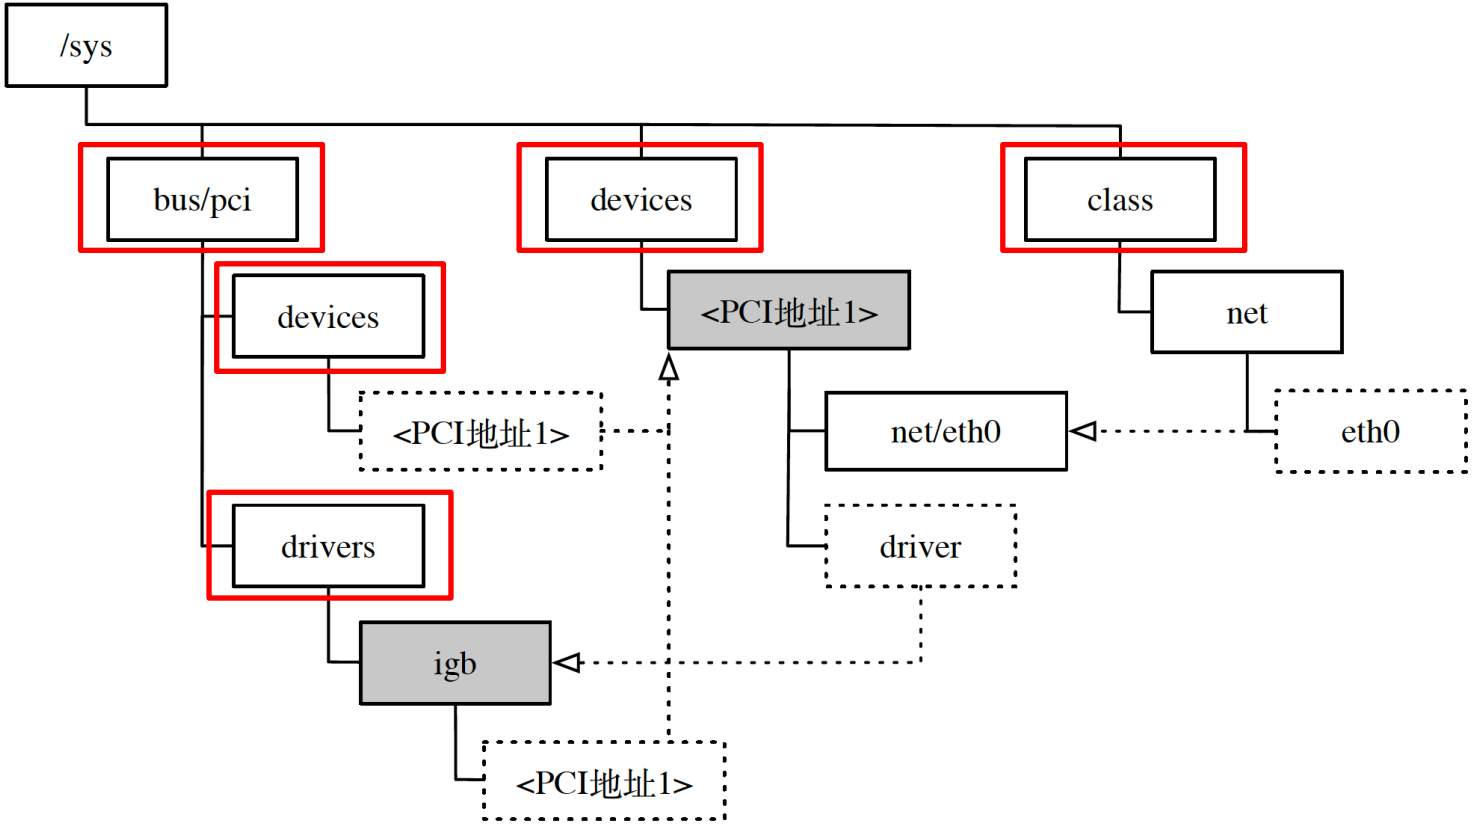
/sys
bus/pci
devices
class
devices
<PCI地址1>
net
<PCI地址1>
net/eth0
eth0
drivers
driver
igb
<PCI地址1>

网络协议栈的分层模型

	应用层	游戏进程或聊天进程
L4	传输层	TCP或UDP协议：端口
L3	网络层	IP协议：主机地址
L2	数据链路层	网络设备驱动
	物理层	网络设备

Linux网络驱动模型

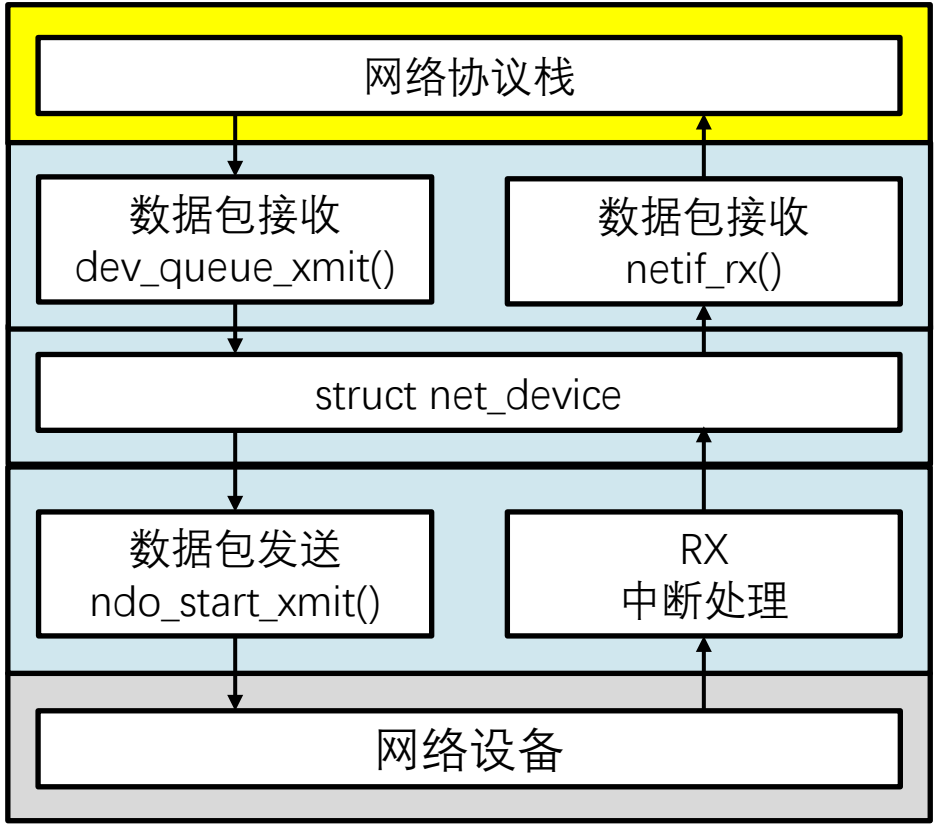

网络协议接口层

网络设备接口层

设备驱动层

物理层

网卡硬中断（ISR）

树莓派3

```
$ cat /proc/interrupts
           CPU0       CPU1       CPU2       CPU3
 17:          0          0          0          0     GICv2  29 Level     arch_timer
 18:    7331554    2731032     433991     492919     GICv2  30 Level     arch_timer
 23:      26740          0          0          0     GICv2 114 Level     DMA IRQ
 31:     757858          0          0          0     GICv2  65 Level     fe00b880.mailbox
 34:       6556          0          0          0     GICv2 153 Level     uart-pl011
 36:          0          0          0          0     GICv2 169 Level     brcmstb_thermal
 37:    8457672          0          0          0     GICv2 158 Level     mmc1, mmc0
 43:          0          0          0          0     GICv2 106 Level     v3d
 45:    7567287          0          0          0     GICv2 189 Level     eth0
 52:         51          0          0          0     GICv2  66 Level     VCHIQ doorbell
 53:          0          0          0          0     GICv2 175 Level     PCIe PME, aerdrv
 54:         40          0          0          0  Brcm_MSI 524288 Edge      xhci_hcd
```

网卡软中断（softirq）

树莓派3

```
$ cat /proc/softirqs
```

	CPU0	CPU1	CPU2	CPU3
HI:	2	0	0	0
TIMER:	4709143	1000453	238535	156693
NET_TX:	12764	272	293	196
NET_RX:	650451	4930	7150	5162
BLOCK:	0	0	0	0
IRQ_POLL:	0	0	0	0
TASKLET:	6775576	36	24	33
SCHED:	4719393	1043269	255401	165523
HRTIMER:	0	0	0	0
RCU:	2878697	423063	251156	170016

网卡收发的情况

树莓派3

```
$ ifconfig
eth0: flags=4099<UP,BROADCAST,MULTICAST>  mtu 1500
        ether dc:a6:32:4b:c4:00  txqueuelen 1000  (Ethernet)

wlan0: flags=4163<UP,BROADCAST,RUNNING,MULTICAST>  mtu 1500
        inet 192.168.10.194  netmask 255.255.0.0  broadcast 192.168.255.255
        inet6 fe80::aa72:beb8:1888:e82e  prefixlen 64  scopeid 0x20<link>
        ether dc:a6:32:4b:c4:01  txqueuelen 1000  (Ethernet)
        RX packets 655811  bytes 164726673 (157.0 MiB)
        RX errors 0  dropped 0  overruns 0  frame 0
        TX packets 21714  bytes 2496958 (2.3 MiB)
        TX errors 0  dropped 0 overruns 0  carrier 0  collisions 0
```

中断合并

- **Interrupt coalescing**
  - 当外设中断次数累计到一定阈值时，再向CPU发送中断
  - 或者到某个timeout，向CPU发送中断
- **可避免“中断风暴”**
- **更少的中断次数意味着：**
  - 更高的吞吐量
  - 但也增加了中断响应的延迟

案例：LINUX的收包过程

Linux收包过程

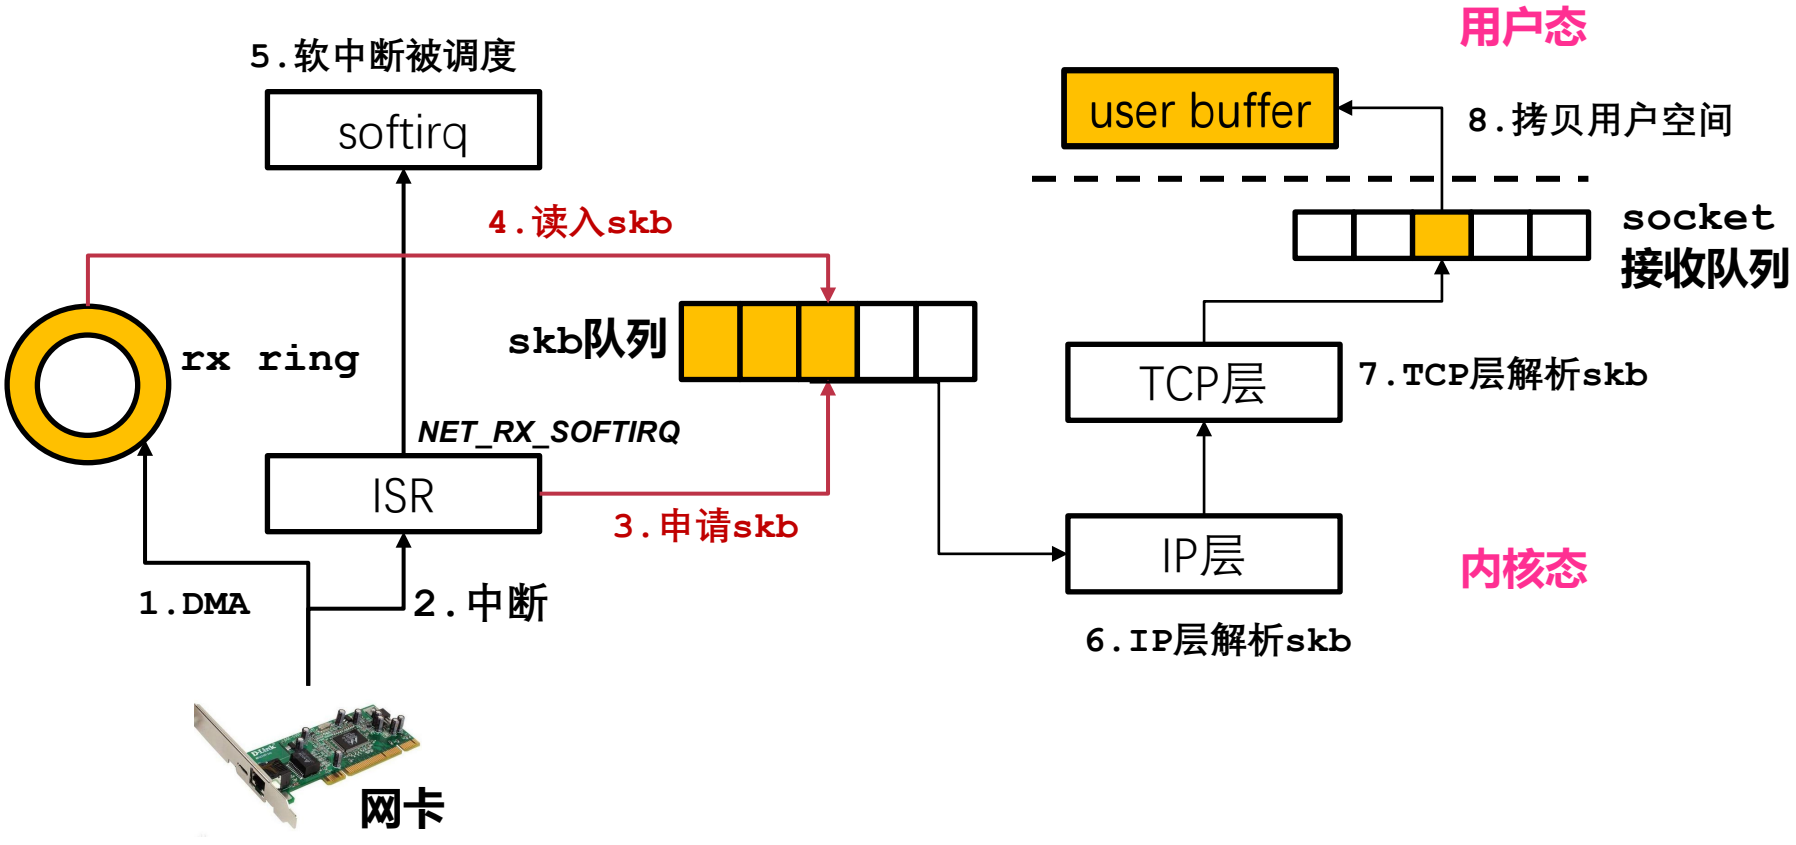
用户态
5.软中断被调度
softirq
user buffer
8.拷贝用户空间
4.读入skb
socket
接收队列
rx ring
skb队列
NET_RX_SOFTIRQ
TCP层
7.TCP层解析skb
ISR
3.申请skb
IP层
内核态
1.DMA
2.中断
6.IP层解析skb
网卡

收包：数据链路层

- **网卡收到到数据包（以太网帧）：**
  - DMA 将数据帧传送至内核内存中的rx_ring
  - 网卡中断被触发
- **CPU收到网卡中断，调用网卡ISR（上半部）：**
  - 分配 *sk_buff (skb)* 数据结构，负责管理rx_ring中的数据包
  - 将skb包入队（*input_pkt_queue*）
- **上半部发出一个软中断（*NET_RX_SOFTIRQ*）：**
  - 通知内核处理skb包

收包：数据链路层（2）

- **进入软中断处理流程（下半部）：**
  - 把 *input_pkt_queue* 的skb移动到 *process_queue* 处理队列中
  - 根据报文类型(ARP或是IP)，把报文递交给对应协议进行处理
  - 调用网络层协议的的handler处理skb包
- **移动skb：操作指针**
- **如果接收队列已满（input_pkt_queue）：**
  - 丢弃后续数据：活锁!

收包：网络层

- **IP 层的入口函数 ip_rcv()：**
  - 检查是否为IP包
  - 检查IP版本号
  - 对完整性（checksum）和长度进行检查
- **ip_rcv()结束调用ip_router_input()，进行路由处理**
  - 查找路由
  - 决定该数据包（报文） 是发到本机，还是被转发，或是被丢弃

收包：传输层

- **传输层的处理入口 tcp_v4_rcv()**
  - 对 TCP header 进行检查
- **调用 _tcp_v4_lookup，查找该数据包对应的open socket**
  - 如果找不到，该数据包被丢弃
  - 否则检查 socket 和 connection 的状态
- **socket 和 connection 正常**
  - 调用 tcp_prequeue() 使tcp载荷从内核进入用户空间，放进 socket 接收队列

收包：应用层

- **socket 被唤醒，调用 system call，并最终调用 tcp_recvmsg()，从 socket 接收队列 中获取数据**
- **用户态调用 read 或者 recvfrom ， 转化为 sys_recvfrom 调用**
  - 对 TCP 来说，调用 tcp_recvmsg()：该函数从socket buffer 中拷贝数据到user buffer

网络包的管理

- **要求高效地处理分层**
  - 发包时需要不断添加新的头部，收包则相反
- **避免连续存放网络包**
  - 移动过程中数据拷贝会有很大开销
- **Linux数据结构：sk_buff（简称skb）**
  - 让分层的处理变得高效：零拷贝
  - 快速申请和释放内存：防止内存碎片

sk_buff

```
struct sk_buff {
    /* These two members must be first. */
    struct sk_buff     * next;
    struct sk_buff     * prev;

    // 真正指向的数据buffer
    struct sock  *sk;

    // 缓冲区的头部
    unsigned char *head;
    // 实际数据的头部
    unsigned char *data;
    // 实际数据的尾部
    unsigned char *tail;
    // 缓冲区的尾部
    unsigned char *end;
};
```

- **sk_buff本身不存储报文**
  - 通过指针指向真正的报文内存空间
- **在各层传递时**
  - 只需调整指针相应位置即可

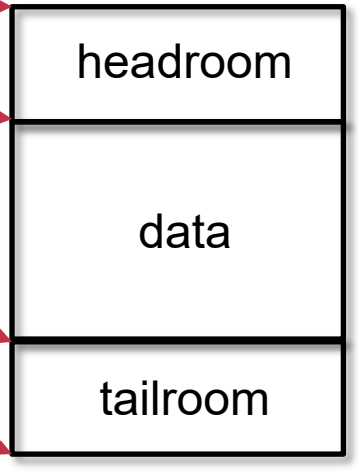

例子：发送数据包

- Step1: TCP层发数据时，首先用alloc_skb申请缓冲区

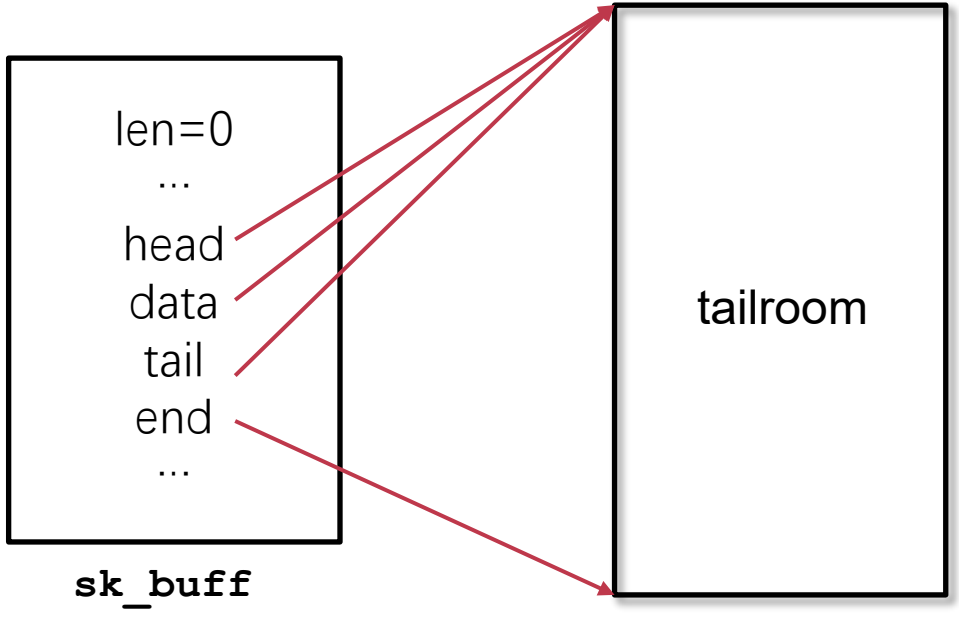

例子：发送数据包

- Step2: TCP用skb_reserve来保留足量空间存储所有头部

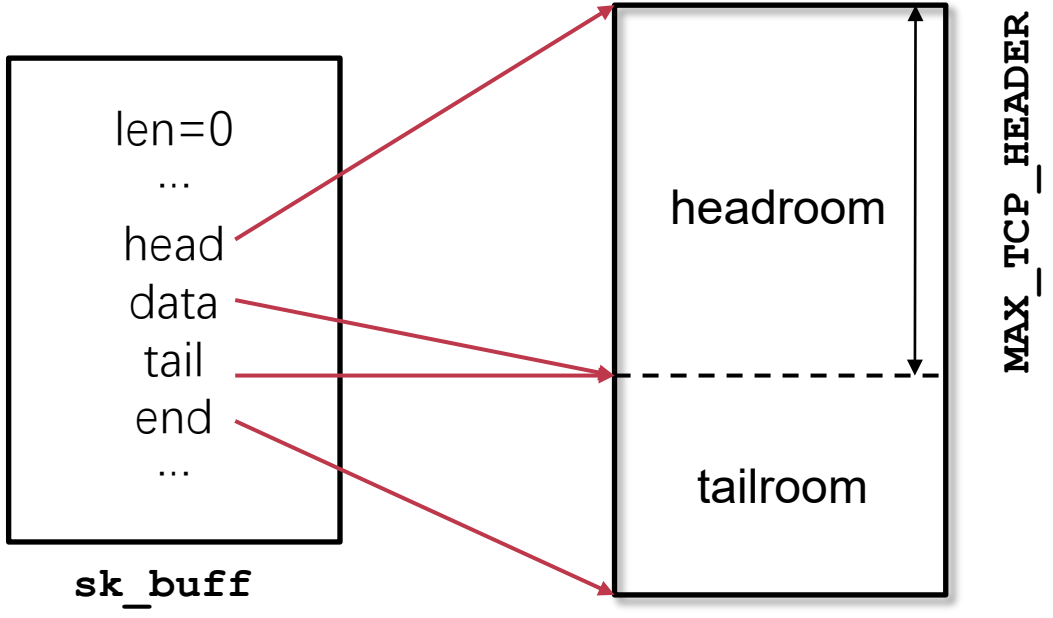

例子：发送数据包

- Step3: TCP层填入TCP负载（应用层数据）

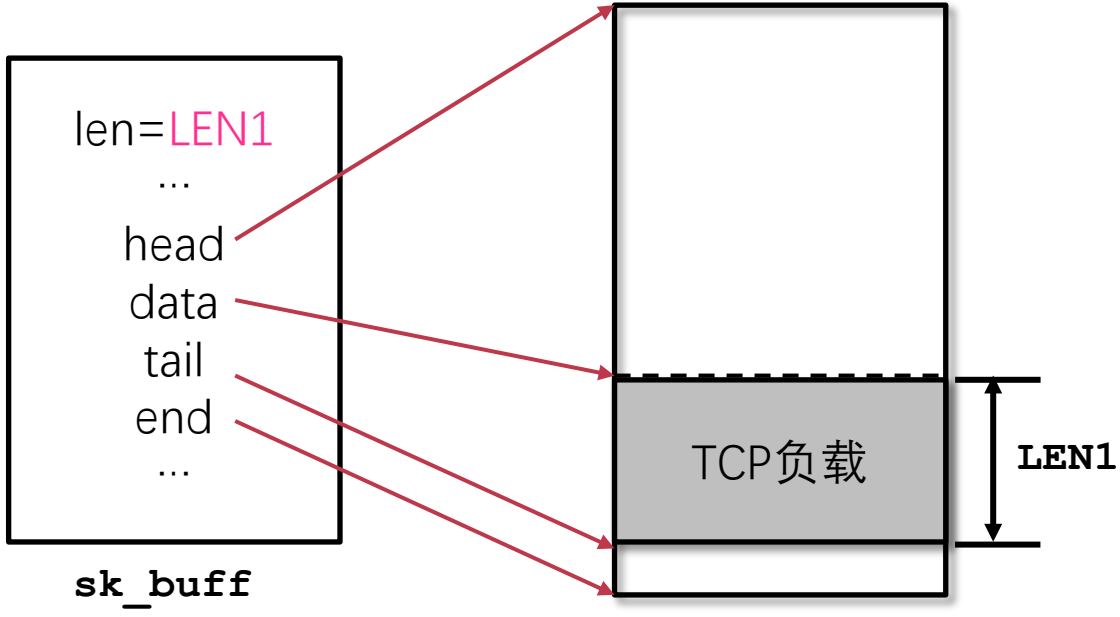

例子：发送数据包

- Step4: TCP层填入TCP头部

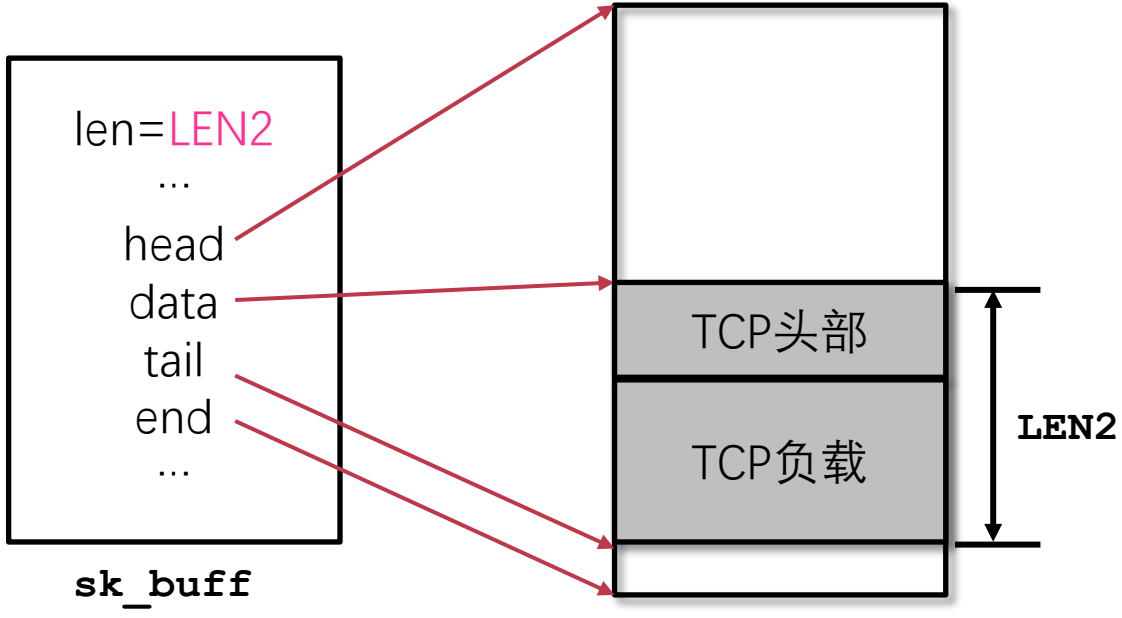

例子：发送数据包

- **Step5: 传给IP层，并添加IP头部**

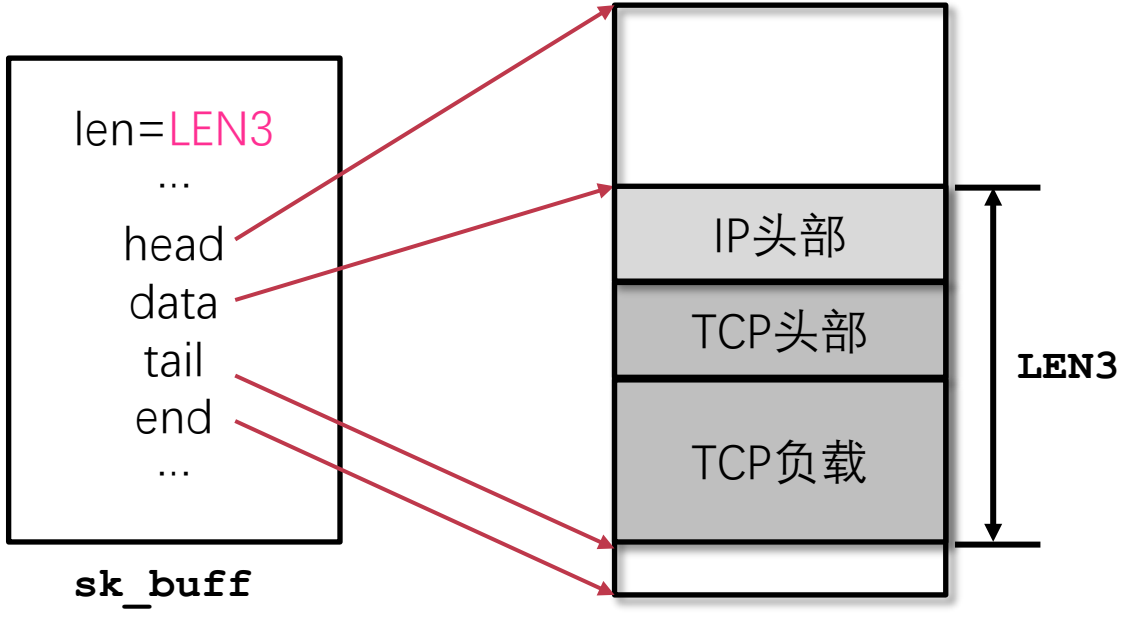

例子：发送数据包

- Step6: 传给链路层，并添加以太网头部

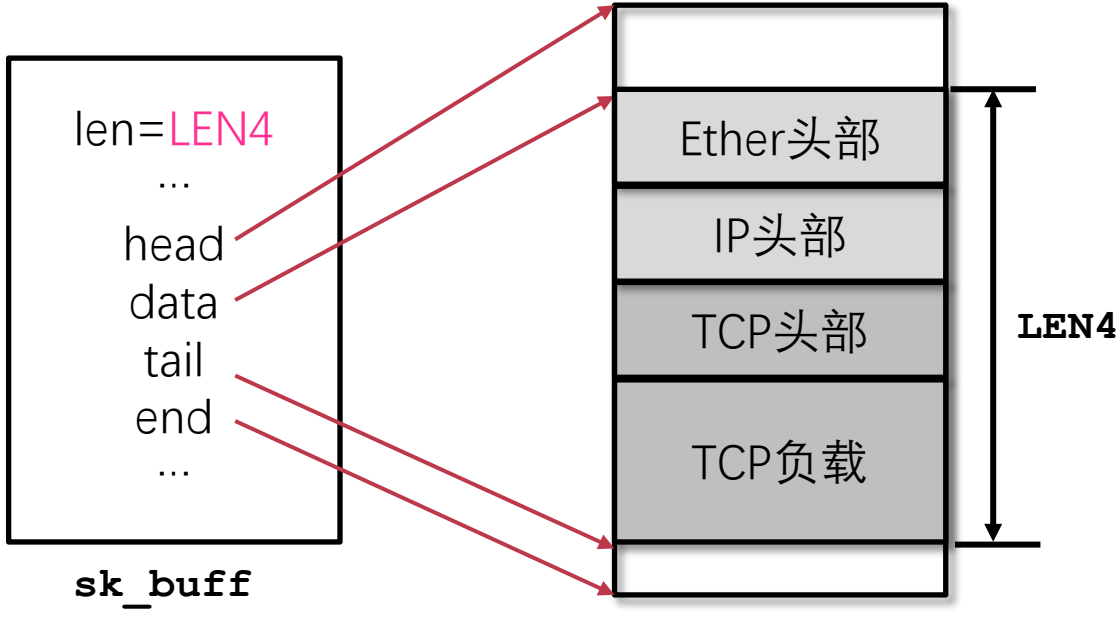

skb的协议栈头部

```
struct sk_buff {
    ... ... ...
    union { ... } h;    // <--- 传输层头部
    union { ... } nh;   // <--- 网络层头部
    union { ... } mac; // <--- 数据链路层头部
    ... ... ...
};
```

- **当前层处理skb时：**
  - 同时负责将下一层头部指针初始化好，并移动data指针

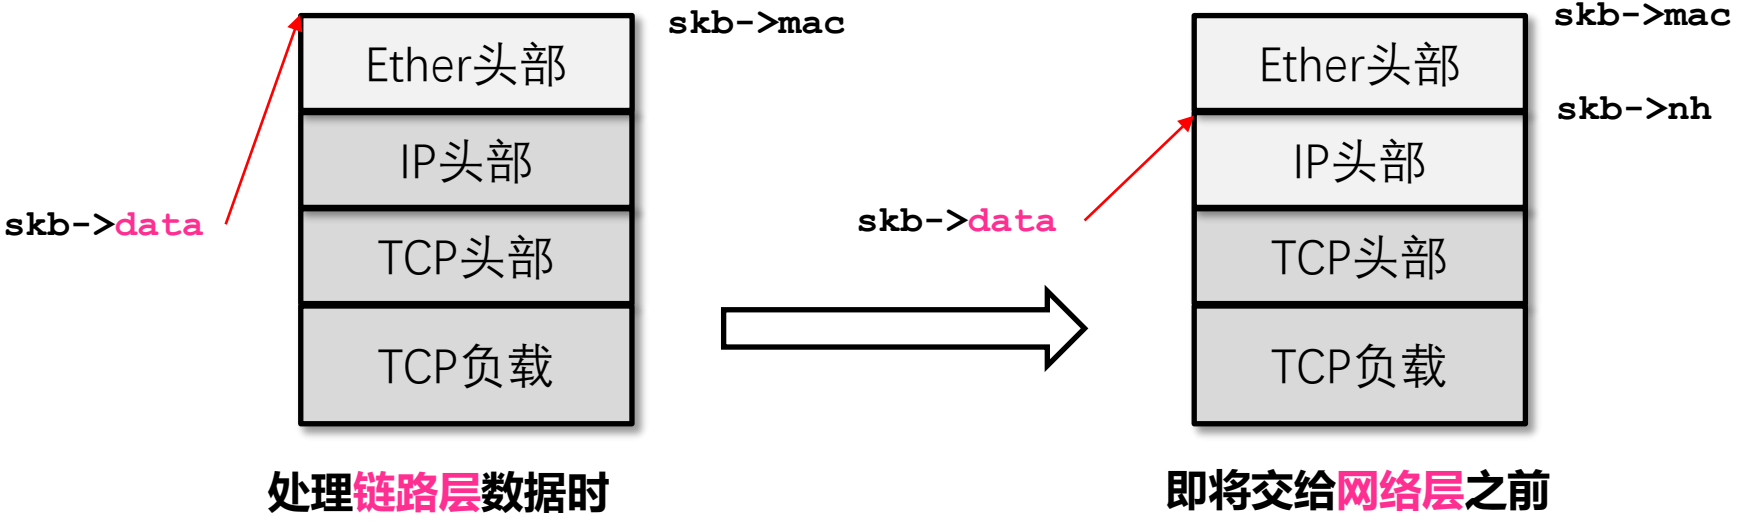

skb control buffer

- char cb[40];
- 用于每层维护私有的信息

```
struct tcp_skb_cb {
    __u32       seq;        /* Starting sequence number */
    __u32       end_seq;    /* SEQ + FIN + SYN + datalen    */
    ... ... ...
    __u8        tcp_flags;  /* TCP header flags. (tcp[13])  */
    __u8        sacked;     /* State flags for SACK.    */
    __u8        txstamp_ack:1,  /* Record TX timestamp for ack? */
    __u32       ack_seq;    /* Sequence number ACK'd    */
    ... ... ...
    };
};
```

skb的组织

- **用双向链表对sk_buff进行管理：**

```
struct sk_buff_head {
    /* These two members must be first. */
    struct sk_buff    * next;
    struct sk_buff    * prev;
    _ _u32          qlen; // 链表的元素长度
    spinlock_t      lock; // 添加元素时必须持有该锁
};
```

- **Linux NAPI的批处理 ***
  - 让网卡中断处理的下半部softirq积累足量的skb
  - NAPI周期性轮询，并一次性处理完所有skb（batching）
  - *netif_receive_skb_list()*

*** Batch processing of network packets, LWN, https://lwn.net/Articles/763056/**

skb的组织

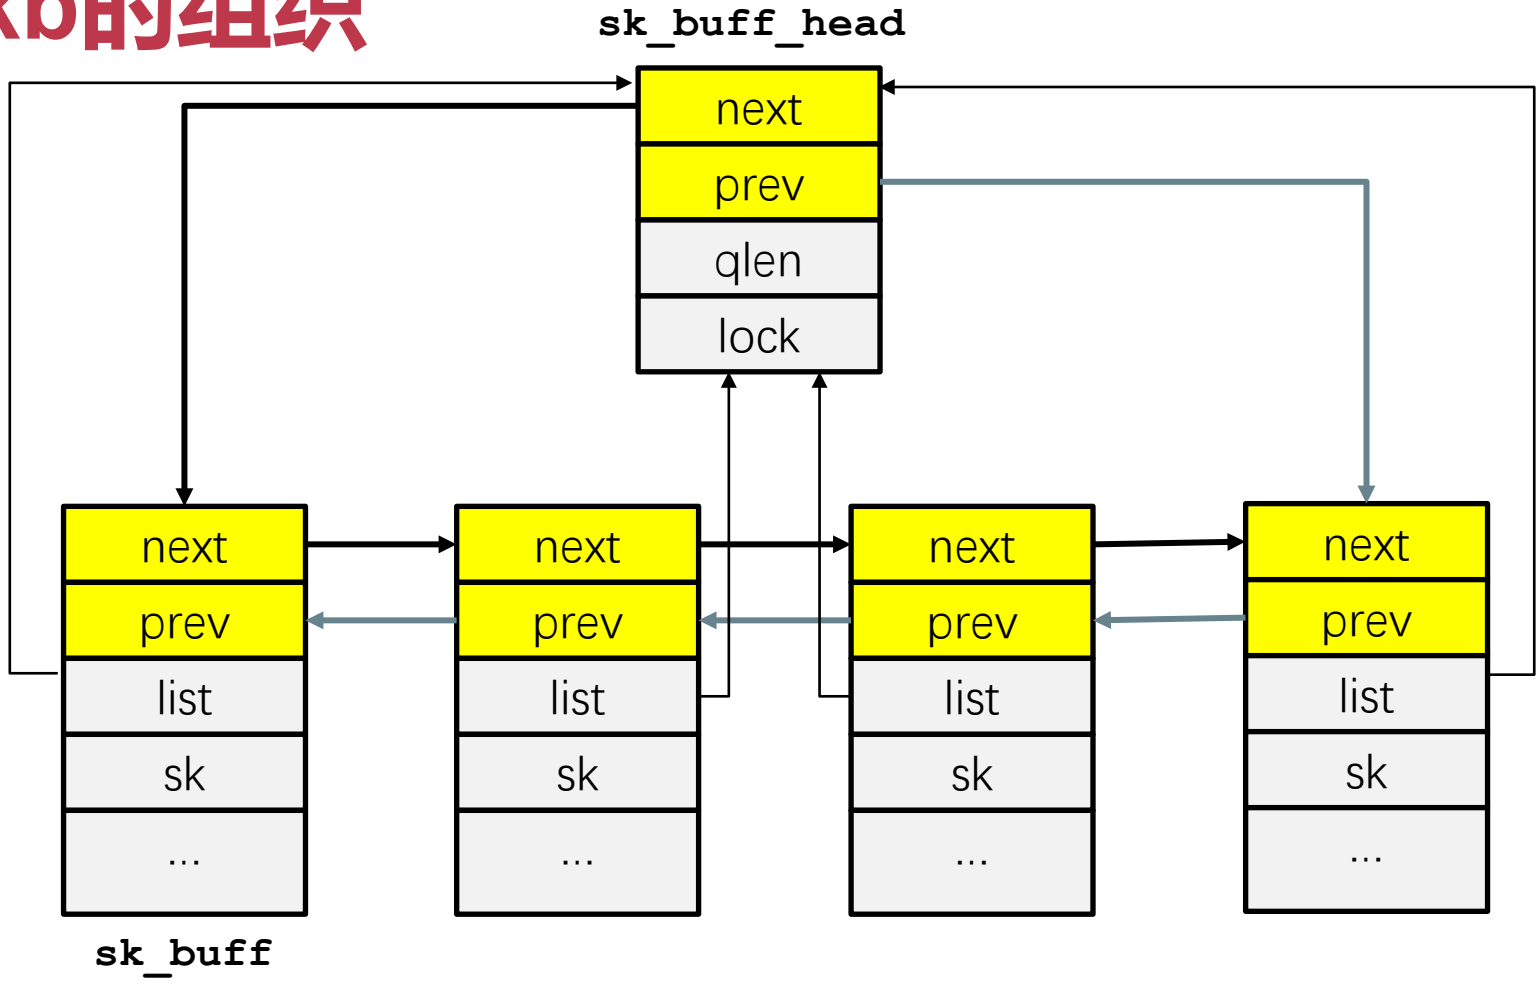
sk_buff_head
next
prev
qlen
lock
next
prev
list
sk
...
next
prev
list
sk
...
next
prev
list
sk
...
next
prev
list
sk
...
sk_buff

skb操作函数

- **分配：struct sk_buff *alloc_skb(unsigned int size,int gfp_mask)**
  - GFP_ATOMIC：分配过程不能被中断，用于中断上下文中分配内存
  - GFP_KERNEL：分配过程可以被中断，分配请求被放到等待队列中
- **浅拷贝：struct sk_buff *skb_clone(struct sk_buff *skb, int gfp_mask)**
  - 克隆出新的sk_buff控制结构，指向同一报文（用于tcpdump等抓包工具）
- **深拷贝：struct sk_buff *skb_copy(struct sk_buff *skb, int gfp_mask)**
  - 同时复制sk_buff以及指向的报文（用于修改报文，如NAT地址转换）
- **释放：void kfree_skb(struct sk_buff *skb)**
- **使用“引用计数”来管理sk_buff**

GFP_ATOMIC

- **alloc_skb()**
  - GFP_ATOMIC：分配过程不能被中断，用于中断上下文中分配内存
  - GFP_KERNEL：分配过程可以被中断，分配请求被放到等待队列中
- **在上半部ISR中：**
  - GFP_ATOMIC保证分配过程不会再有ISR打断
- **在下半部软中断中：**
  - GFP_ATOMIC告诉内核，如果申请失败，不能进入睡眠

skb操作函数

- **unsigned char *skb_push(struct sk_buff *skb, unsigned int len)**
  - 在存储空间的头部增加存储网络报文的空间，**用于发送网络报文时添加包头**
- **unsigned char *skb_put(struct sk_buff *skb, unsigned int len)**
  - 在存储空间的尾部增加存储网络报文的空间，**用于发送网络报文时追加数据**
- **unsigned char *skb_pull(struct sk_buff *skb, unsigned int len)**
  - 使data指针指向下一层网络报文的头部，**用于接收网络报文时调整头部**
- **void skb_reserve(struct sk_buff *skb, unsigned int len)**
  - 在存储空间的头部预留len长度的空隙，**用于为协议头部保留空间**
- **void skb_trim(struct sk_buff *skb, unsigned int len)**
  - 将网络报文的长度缩减到*len*，用于丢弃网络报文尾部的填充值

skb_push

- 将skb的data指针往上推

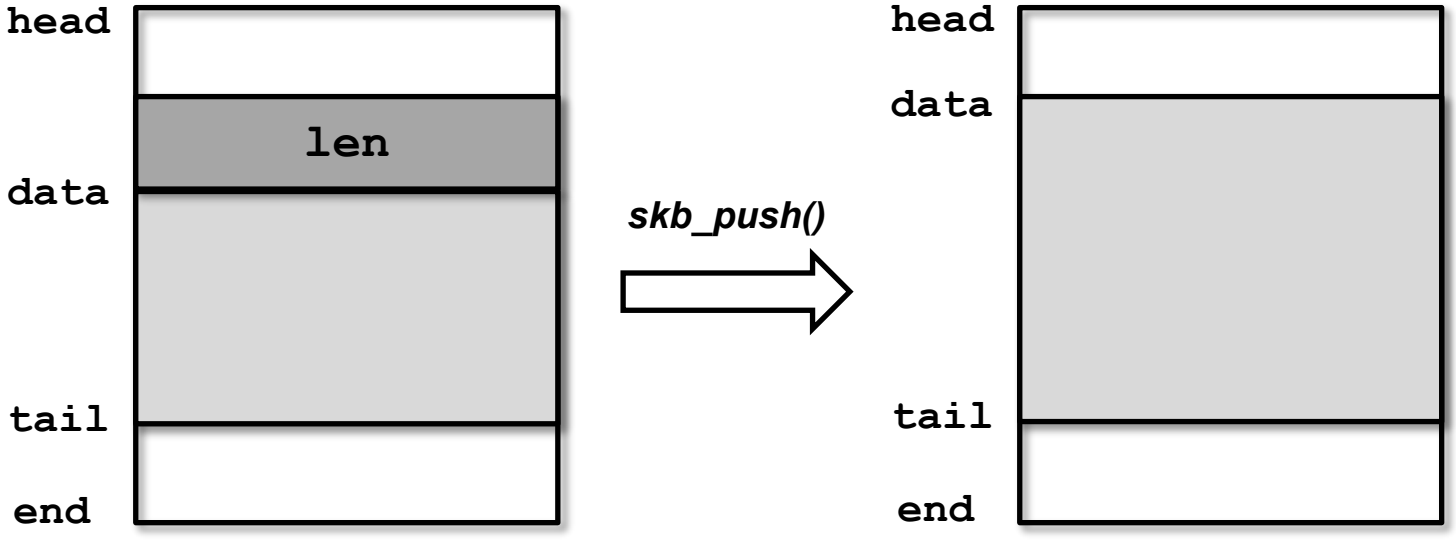

- 用于TCP层或IP层封装头部

skb_put

- 将skb的tail指针往下移

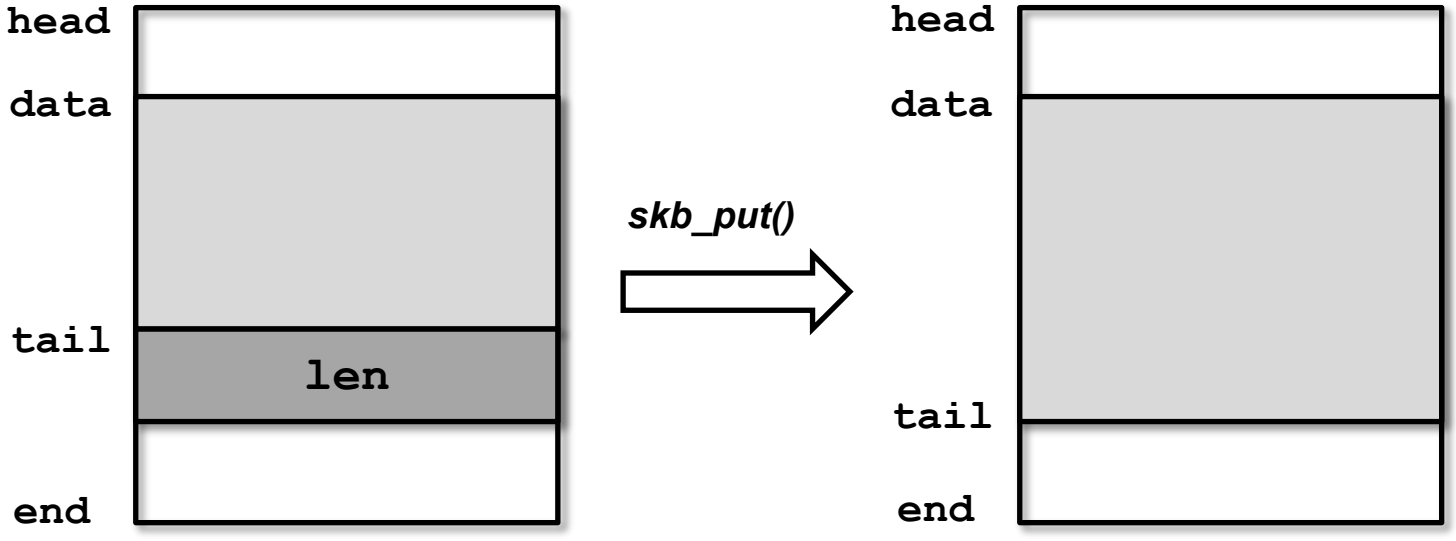

- 用于DMA接收数据包，或*copy_from_user*()发送数据包

skb_pull

注意：头部并没有从skb中删除！

- 将skb的data指针往下拉

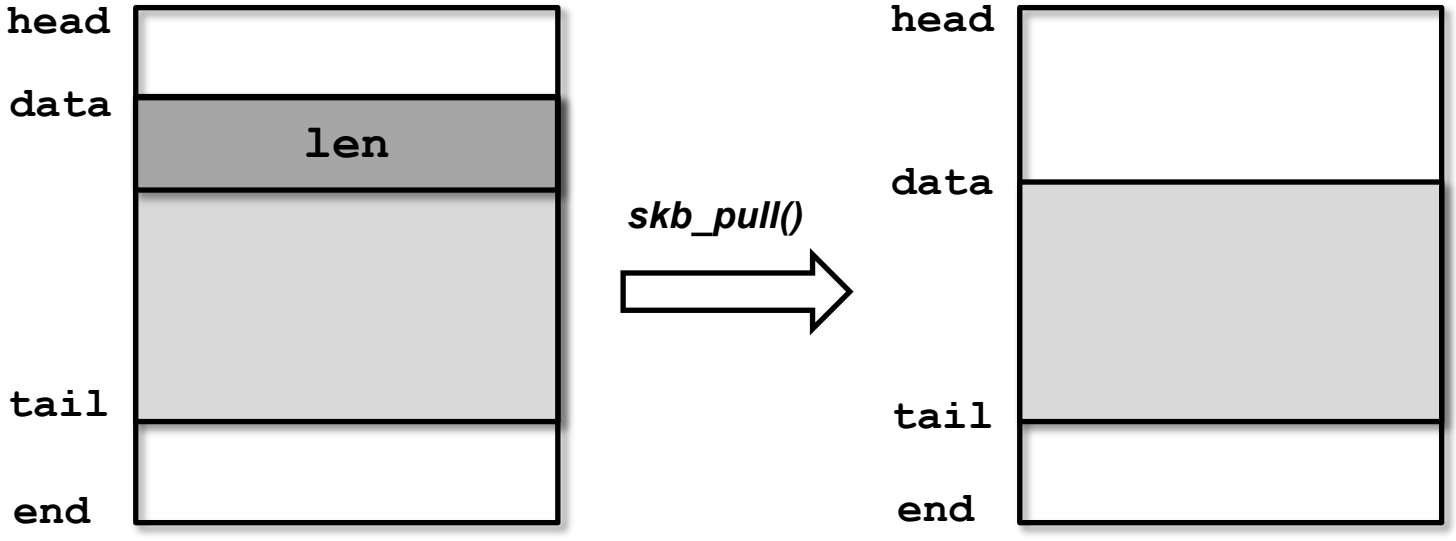

- 用于IP层和TCP接收数据包时移除头部

skb总结

- **sk_buff**
  - 用于 Linux 网络子系统中各层之间的数据传递
  - 不同协议层的处理函数通过控制sk_buff结构来共享网络报文
- **收包:**
  - 网卡收到数据包后，将以太网帧数据转换为sk_buff数据结构
  - 各层剥去相应的协议头部，直至交给用户
- **发包:**
  - 网络模块必须建立一个包含待传输的数据包的sk_buff
  - 各层在sk_buff 中添加对应的协议头部直至交给网卡发送

Linux网络协议栈的问题

- 网络设备的速度越来越高
- CPU朝着多核方向发展

- 内核协议栈逐渐成为高性能网络的**性能瓶颈**

Linux网络协议栈的问题

- **中断处理**
  - 大量网络包到来→频繁的硬件中断请求
  - 中断频繁打断较低优先级的软中断或者系统调用的执行过程→网络处理缓慢
- **上下文切换**
  - 线程间的调度产生频繁上下文切换开销
  - 锁竞争的开销严重：cacheline sharing
- **内存拷贝**
  - 数据从网卡DMA传到内核缓冲区，再从内核空间拷贝到用户空间
  - 占据Linux 内核协议栈数据包整个处理流程的 57.1%

Linux网络协议栈的问题

- **内存管理**
  - 内存页大小为4K，对TLB要求更高

- **局部性失效**
  - 数据包处理可能跨多核：导致CPU 缓存失效，空间局部性差
  - NUMA 架构：存在跨 NUMA内存访问，性能影响很大

用户态协议栈：DPDK

Intel DPDK

- **Data Plane Development Kit**
- **绕过Linux内核协议栈（bypass kernel）**
  - 直接在用户空间实现数据包的收发和处理

- **Linux User I/O**
  - 在用户态访问 MMIO（和设备交互）与DMA ring buffers
- **轮询模式驱动：**Poll Mode Driver (PMD)

DPDK架构图

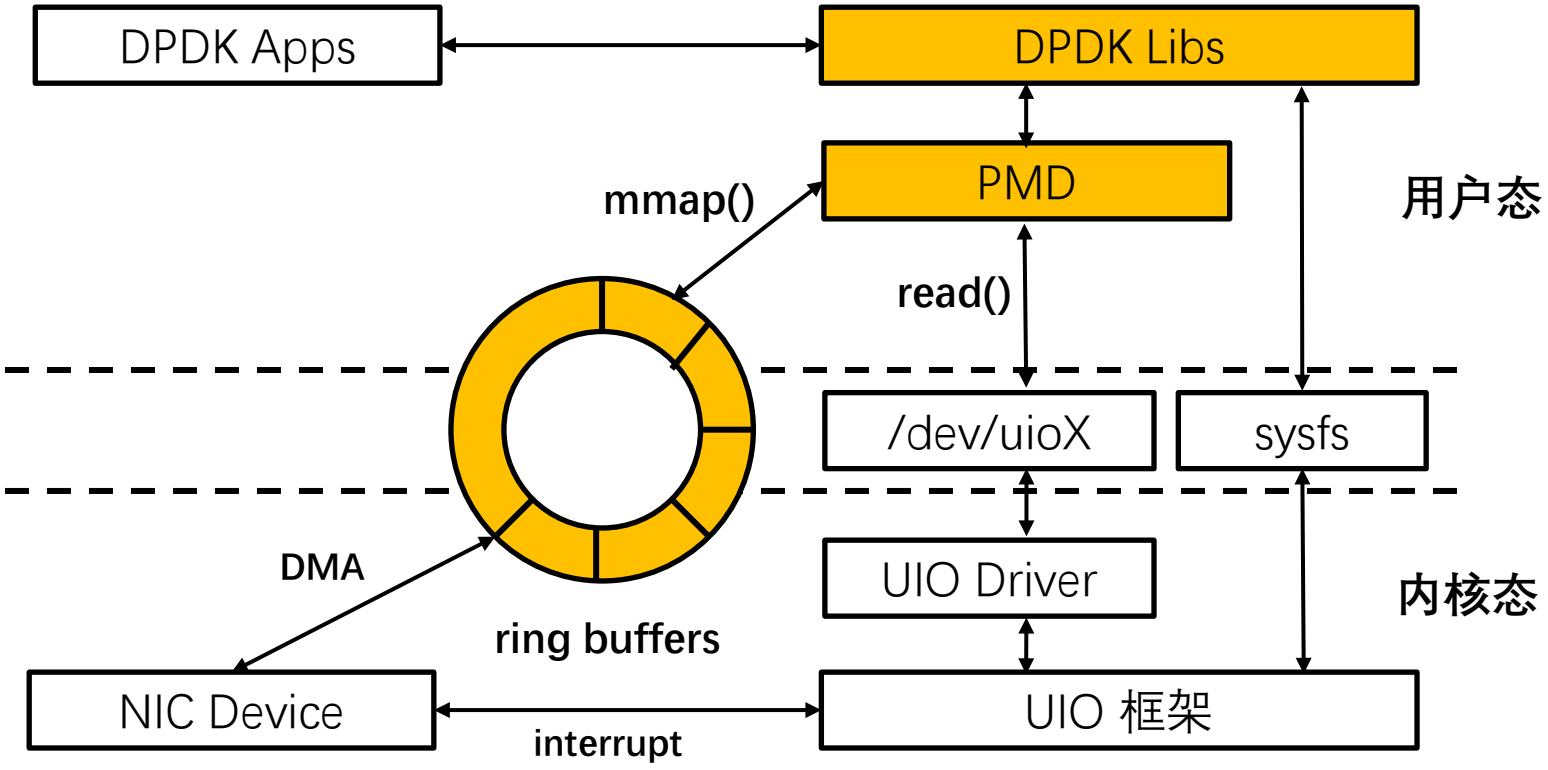
DPDK Apps
DPDK Libs
PMD
mmap()
read()
用户态
/dev/uioX
sysfs
DMA
ring buffers
UIO Driver
内核态
NIC Device
interrupt
UIO 框架

DPDK特性

- **抛弃中断，使用轮询模式**
- **使用大页（2MB），减少TLB miss**

- **控制平面与数据平面相分离：**
  - 内核态负责“控制平面”：内核仅负责控制指令的处理
  - 用户态负责“数据平面”：将数据包处理、内存管理、处理器调度等任务转移到用户空间去完成，有效避免了繁重的模式切换

DPDK特性（2）

- **用多核编程代替多线程技术**
  - 绑核：设置 CPU 亲和性，减少彼此间调度切换
  - 无锁环形队列：解决资源竞争问题

- **CPU 核尽量使用所在 NUMA 节点的内存**
  - 避免跨NUMA内存访问

DPDK的使用

- **DPDK本身只是2层协议，不提供socket接口**
  - 适合于软路由场景

- **如果要用于应用程序，提供socket抽象**
  - **类微内核方案**：将 **DPDK+TCP/IP协议栈** 作为一个Server，为每个应用单独维护 socket fd 和进程间的对应关系
  - **LibOS方案**：需要逐个应用添加协议栈支持

类微内核方案

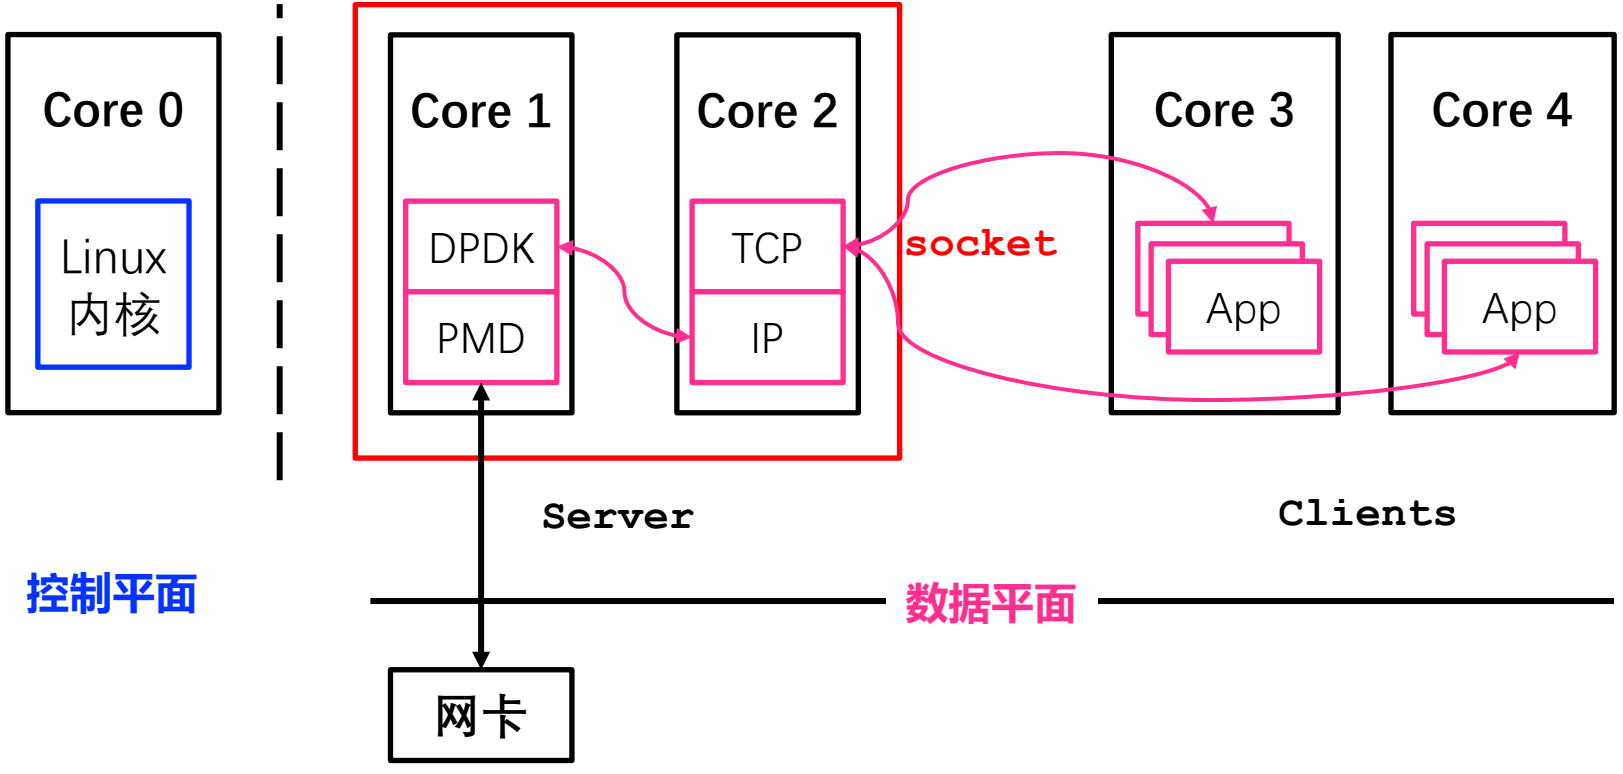
Core 0
Linux
内核
Core 1
DPDK
PMD
Core 2
TCP
IP
socket
Core 3
App
Core 4
App
Server
Clients
控制平面
数据平面
网卡

LibOS方案

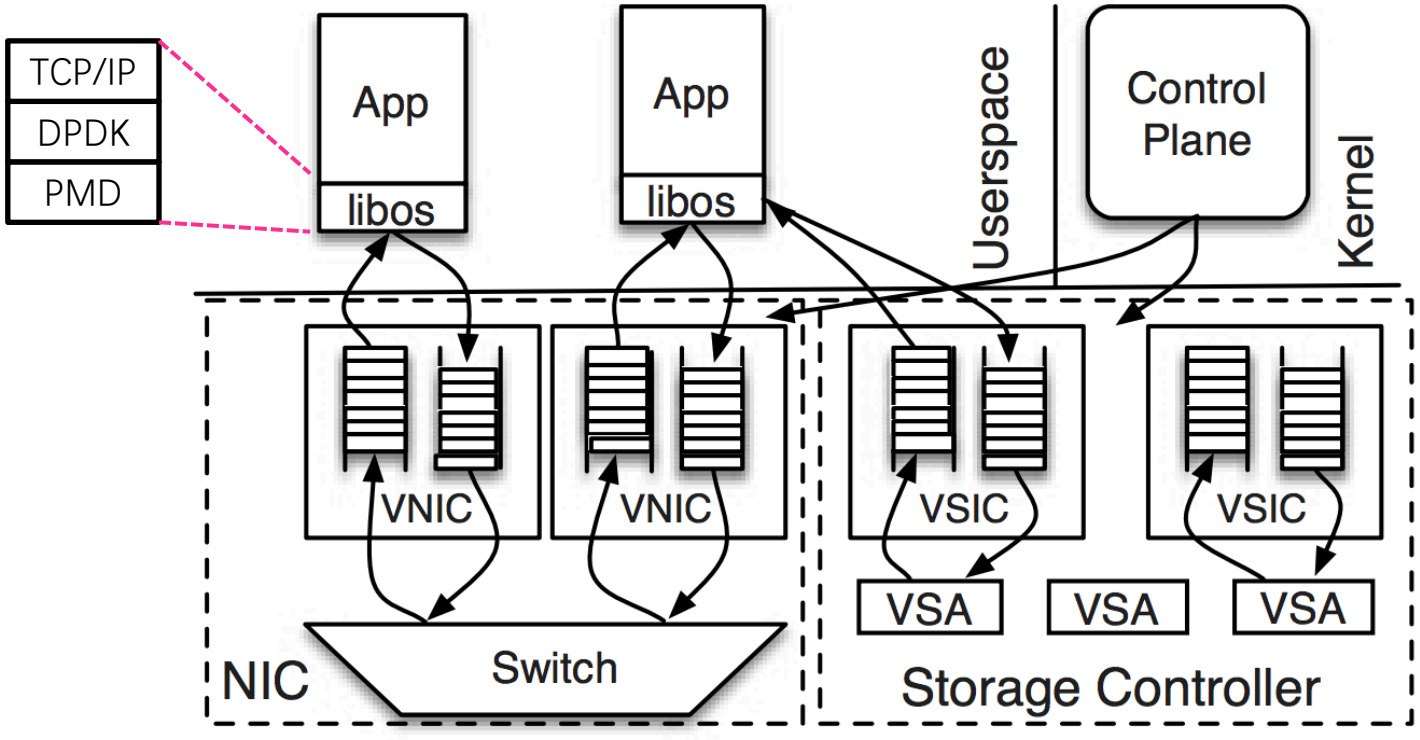

Arrakis: The Operating System is the Control Plane, OSDI 2014

控制平面与数据平面分离

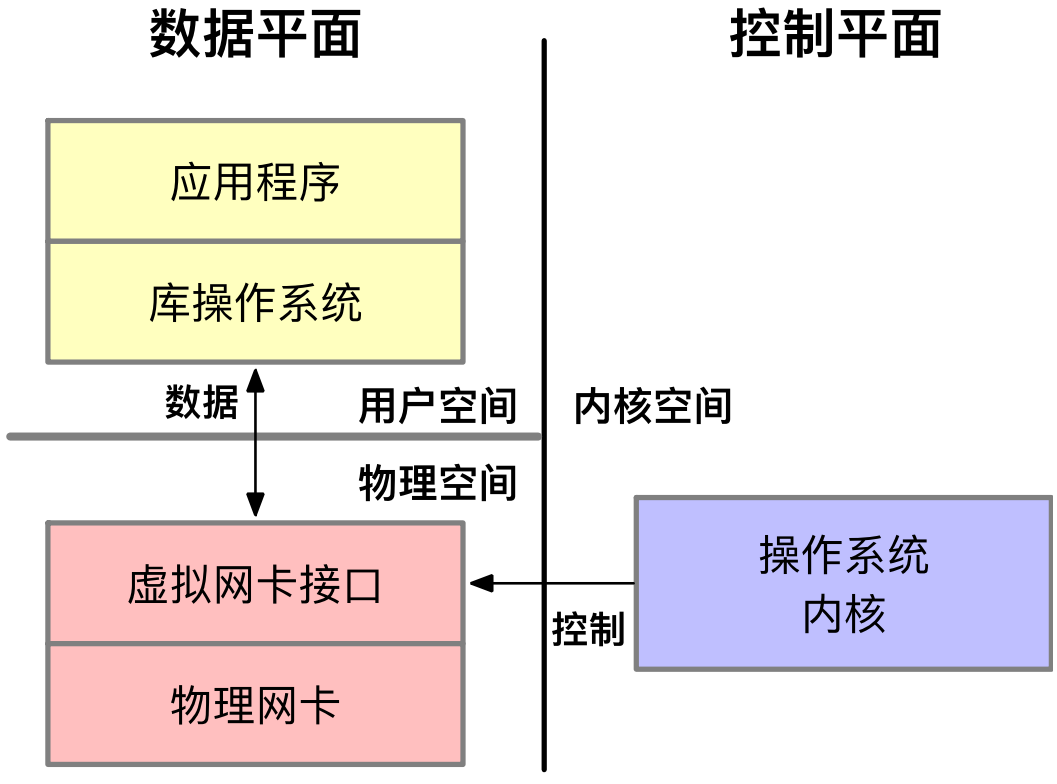

微内核协议栈： CHCORE

ChCore网络架构图

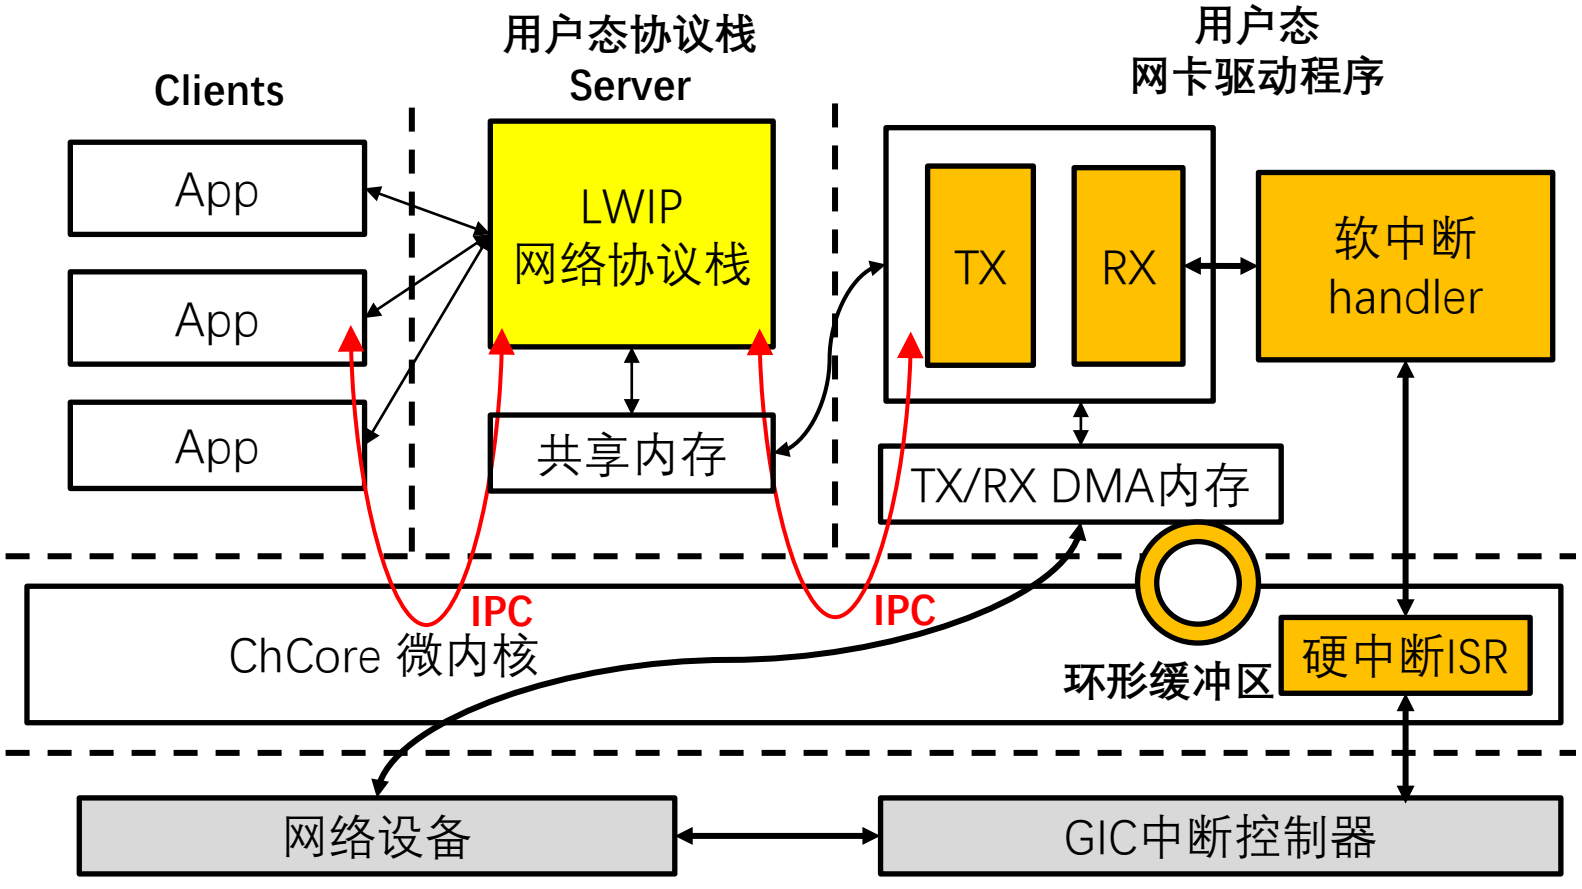

PCI设备

- **PCI总线为设备提供了标准机制**
  - 发现设备
  - 分配中断、物理内存空间和I/O空间
- **三层架构**
  - bus
  - device
  - function

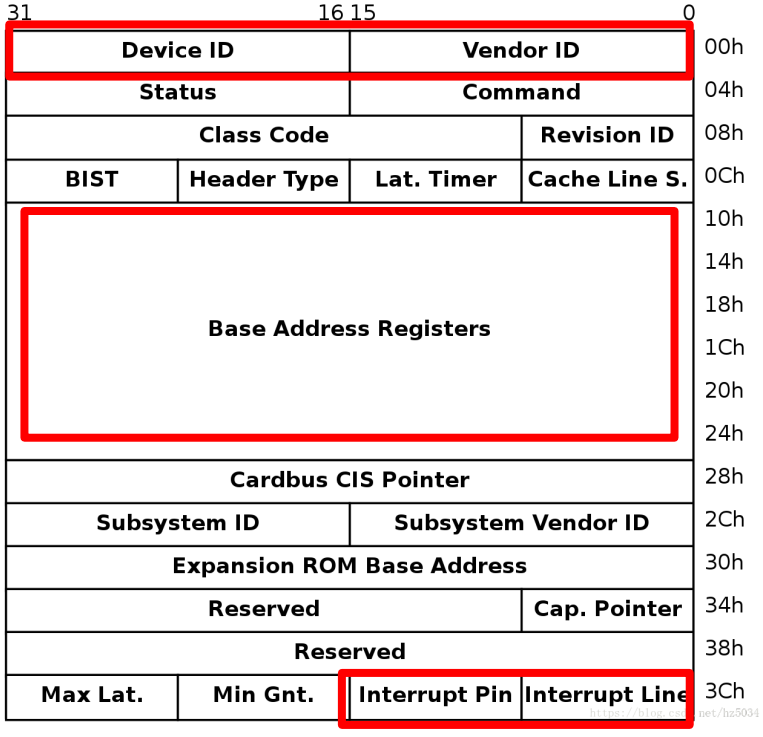

找到目标网卡

```
struct pci_driver pci_attach_devs[] = { { 0x10ec, 0x8139, &rtl8139_attach }, };

static int pci_attach(struct pci_func *f) /* 根据vendor_id和product_id检测rtl8139网卡 */
{
    uint32_t vendor_id = PCI_VENDOR(f->dev_id);
    uint32_t product_id = PCI_PRODUCT(f->dev_id);
    for (int i = 0; i < sizeof(pci_attach_devs) / sizeof(pci_attach_devs[0]); i++)
        if (pci_attach_devs[i].vendor_id == vendor_id && pci_attach_devs[i].product_id == product_id)
            int r = pci_attach_devs[i].attachfn(f);
    return -ESUPPORT;
}

static void init_pci()
{
    static struct pci_bus root_bus = { 0 };
    f_iter_dev.bus = &root_bus;
    for (f_iter_dev.dev = 0; f_iter_dev.dev < 32; f_iter_dev.dev++) {
        ...
        intr = pci_conf_read(&f, PCI_INTERRUPT_REG);
        f.irq_line = PCI_INTERRUPT_LINE(intr); // 获取中断线
        f.dev_class = pci_conf_read(&f, PCI_CLASS_REG);
        pci_attach(&f);
    }
}
```

网卡初始化

```
struct rtl8139_dev_t
{
    uint64_t io_base, mem_base, irq_num;
    uint8_t  mac_addr[6];
    uint64_t rx_curr, tx_curr; // 缓冲区的当前偏移量
    void *   rx_buffer; // DMA缓冲区
    void *   tx_buffer;
} rtl8139_device;

static void rtl8139_initialize()
{
    // 初始化PCI配置空间
    rtl8139_device.io_base  = RTL8139_IO_VADDR & ~0xf;
    rtl8139_device.mem_base = RTL8139_MEM_VADDR;

    rtl8139_probe(); // 探测网卡设备

    // 申请 RX 缓冲区
    rtl8139_device.rx_buffer = rtl8139_kmalloc(RX_BUF_LEN, RTL8139_RX_DMA_VADDR, &kern_dma_addr);

    // 申请 TX 缓冲区
    rtl8139_device.tx_buffer = rtl8139_kmalloc(TX_BUF_SIZE, RTL8139_TX_DMA_VADDR, &kern_dma_addr);
}
```

用户态中断处理函数

```
static void rtl8139_handler()
{
    uint16_t status = inports(rtl8139_device.io_base + 0x3e);
    outports(rtl8139_device.io_base + 0x3e, 0x5); // 向网卡确认中断

    if (status & ROK) {
        rtl8139_receive();  // 处理RX中断
    } else (status & TOK) ; // 判断TX中断
}

#define ARM_VIRT_NIC_IRQ    0x24
static void * nic_irq_handler(void * args)
{
    int irq_cap = usys_irq_register(ARM_VIRT_NIC_IRQ);
    while (1) {
        usys_irq_wait(irq_cap, true); // 等待ChCore内核向用户空间发送软中断
        rtl8139_handler();            // 网卡中断处理函数
        usys_irq_ack(irq_cap);        // 向ChCore确认，软中断已经收到
    }
    usys_exit(0);
    return NULL;
}
```

驱动和协议栈IPC交互

- **协议栈rtl8139_receive线程调用obtain_pkt()**
  - 将数据包组装成lwip的pbuf（类似Linux的skb）
  - 将pbuf加入共享内存的队列中
- **obtain_pkt ← IPC → lwip的RX线程**
  - lwip从队列中获取pbuf并进行解析，得到最终数据
- **lwip server线程 ← IPC → 用户态程序socket**
  - 用户程序使用socket，调用SYS_socket
  - SYS_socket被trap为IPC，从lwip server获取网络数据

不同架构对比

架构对比

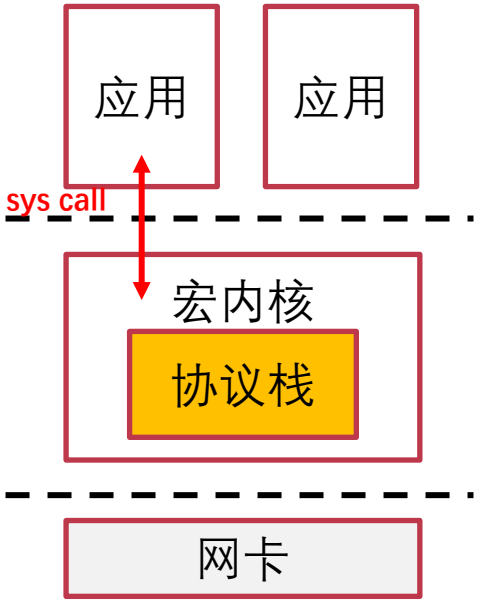

宏内核系统

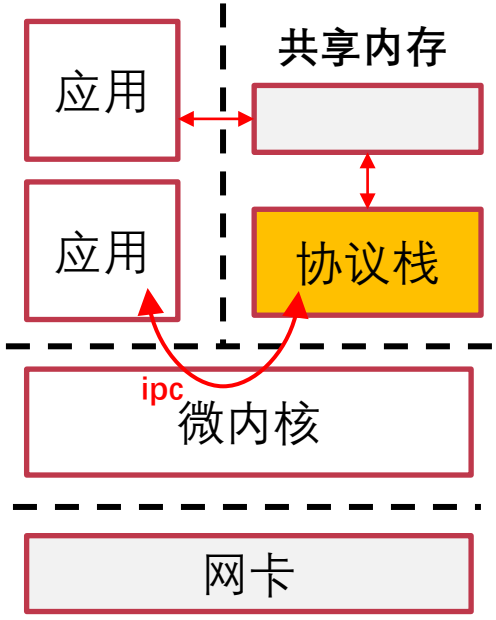

微内核系统

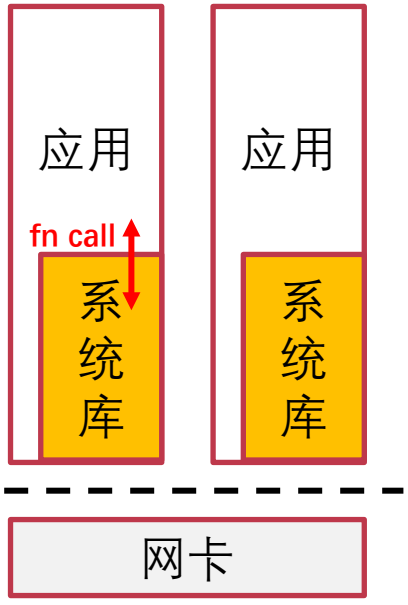

库操作系统

不同系统架构下网络设计对比

- **宏内核系统网络模块：**
  - 控制平面和数据平面都经过内核
  - 驱动和协议栈处在同一地址空间，没有模式切换
  - 驱动程序的安全问题会波及协议栈

不同系统架构下网络设计对比

- **微内核系统网络模块：**
  - 用户态驱动+协议栈，安全性好
  - 只有一个协议栈，运维成本低
  - 控制平面通信需要借助IPC完成，有一定开销

不同系统架构下网络设计对比

- **库操作系统（LibOS）网络模块：**
  - 用户态或non-root模式下协议栈，鲁棒性好
  - 每个实例都有自己的协议栈
  - 一旦需要更新，可维护性成本高
  - 多实例polling的情况下会导致浪费CPU*

Snap: a Microkernel Approach to Host Networking, SOSP 2019

下次课内容

- **虚拟化**